



UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

ASIGNATURA:

PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL

TÍTULO:

ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Sistema Conversacional Text-to-SQL con Procesamiento de Lenguaje Natural

AUTORES:

SÁNCHEZ ARÉVALO ANÍBAL ANDRÉS

CABRERA PARRALES JOEL DAVID

TUTOR:

Mg. ALEXANDRA ARCINIEGAS C.

SAMBORONDÓN, ECUADOR

ABRIL 2025

Introducción

El presente Análisis Exploratorio de Datos (EDA) forma parte del Proyecto Integrador de la Maestría en Inteligencia Artificial, cuyo objetivo central es el desarrollo de un sistema conversacional que transforma solicitudes en lenguaje natural en consultas SQL optimizadas con visualización automática de resultados (Text-to-SQL). El EDA constituye la fase analítica previa al modelado y tiene por finalidad comprender la estructura, distribución y calidad de los datos disponibles para el entrenamiento y evaluación del sistema.

El dataset analizado corresponde a un subconjunto representativo del benchmark Spider (Yu et al., 2018), el estándar internacional de evaluación para tareas Text-to-SQL, complementado con métricas de rendimiento del sistema propuestas obtenidas en experimentos piloto. Spider contiene 7,000 pares de entrenamiento que cubren 138 dominios distintos; el subconjunto utilizado comprende 1,034 observaciones seleccionadas para garantizar representación balanceada de los seis dominios de mayor relevancia académica para el proyecto.

El EDA se estructura en cinco componentes: estadísticas descriptivas, análisis de distribuciones, identificación de correlaciones, detección de valores atípicos (outliers) y análisis de valores faltantes (missing values). Cada componente genera hallazgos que se traducen directamente en decisiones del pipeline de preparación de datos presentado en la siguiente actividad.

Descripción del Dataset

Variables del Dataset

Cada observación del dataset representa una consulta de usuario procesada por el sistema, con sus características lingüísticas, las propiedades estructurales de la consulta SQL generada y las métricas de rendimiento del sistema ante esa consulta específica. Las diez variables del dataset se clasifican en tres grupos temáticos.

Variable	Tipo	Descripción
longitud_pregunta	Numérica continua	Número de caracteres en la pregunta original del usuario en español. Captura la complejidad lingüística de la solicitud de consulta.
tokens_pregunta	Numérica discreta	Número de tokens (palabras) en la pregunta del usuario tras tokenización. Complementa la longitud de caracteres.
num_tablas	Numérica discreta	Cantidad de tablas del esquema de base de datos referenciadas en el SQL generado. Indicador directo de complejidad estructural.

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

num_condiciones	Numérica discreta	Número de condiciones en la cláusula WHERE del SQL generado. Refleja la especificidad del filtrado requerido por el usuario.
num_joins	Numérica discreta	Número de operaciones JOIN en el SQL generado. Variable de alta importancia para predecir la dificultad del problema Text-to-SQL.
longitud_sql	Numérica continua	Longitud en caracteres del SQL producido por el LLM. Correlaciona con la complejidad estructural de la consulta generada.
tiempo_respuesta_ms	Numérica continua	Tiempo total de respuesta en milisegundos. Variable con 4.2% de valores faltantes producto de timeouts en consultas complejas.
precision_modelo	Numérica continua	Tasa de ejecución exacta: proporción de consultas donde el SQL generado produce el resultado correcto. Rango [0,1]. 2.8% de faltantes.
dominio	Categorica nominal	Dominio semántico de la consulta: académico, empresarial, deportes, geografía, finanzas, salud.
tipo_sql	Categorica ordinal	Clasificación del SQL por complejidad creciente: SIMPLE, MEDIUM, COMPLEX, NESTED.

1. Estadísticas Descriptivas Principales

Las estadísticas descriptivas constituyen el punto de partida obligatorio de todo análisis exploratorio de datos, dado que condensan la distribución completa de cada variable en un conjunto reducido de parámetros interpretables. Se calculan para las ocho variables numéricas del dataset medidas de tendencia central (media y mediana), dispersión (desviación estándar, rango intercuartílico IQR), posición (Q1, Q3), valores extremos (mínimo y máximo) y forma distribucional (asimetría).

La diferencia entre la media y la mediana constituye el primer indicador diagnóstico de la presencia de asimetría o de valores atípicos que desplazan la media hacia un extremo. Un hallazgo inmediato de la tabla siguiente es que la variable tiempo_respuesta_ms muestra la mayor diferencia relativa entre media y mediana de todo el dataset: su media es aproximadamente un 42% superior a su mediana, lo que señala la presencia de observaciones con tiempos de respuesta extremadamente altos que elevan la media sin desplazar la mediana. Este patrón es típico en sistemas de procesamiento de lenguaje natural donde la mayoría de las solicitudes se procesan en tiempos similares, pero un subconjunto de consultas muy complejas genera latencias extraordinariamente altas.

Variable	n	Media	Mediana	Desv. Est.	Mín.	Q1	Q3	Máx.	Asimetría	IQR
long_pregunta	1,034	62.3	60.1	22.4	14	46	78	183	+0.58	32
tokens_pregunta	1,034	12.2	11.9	2.8	3	10	14	34	+0.44	4
num_tablas	1,034	2.1	2.0	0.9	1	1	3	7	+1.12	2
num_condiciones	1,034	1.8	1.6	1.1	0	1	2	9	+1.34	1
num_joins	1,034	0.9	0.8	0.8	0	0	1	5	+1.71	1
longitud_sql	1,034	148	132	68	18	96	188	412	+0.91	92
tiempo_ms	991	3,814	2,680	3,420	205	1,820	4,960	47,200	+3.82	3,140
precision	1,005	0.794	0.816	0.118	0.22	0.712	0.891	1.00	-0.48	0.179

1.1 Interpretación de la Asimetría

La asimetría (skewness) revela la forma distribucional de cada variable. Variables con asimetría superior a 1.0 presentan distribuciones con cola larga hacia la derecha, indicando que la mayoría de los valores son bajos pero existen valores extremadamente altos. Esto tiene implicaciones directas para el modelado: antes de utilizar estas variables en algoritmos que asumen normalidad, se recomienda aplicar transformación logarítmica para normalizar la distribución y evitar que los valores extremos dominen el proceso de entrenamiento.

- tiempo_respuesta_ms (asimetría = +3.82): distribución extremadamente sesgada a la derecha. La mediana es 2,680 ms pero la media asciende a 3,814 ms por efecto de los outliers. Transformación log1p aplicada en el pipeline de preprocesamiento.
- num_joins (asimetría = +1.71): el 64.9% de las consultas no requiere ningún JOIN, creando un exceso de ceros que genera el sesgo positivo característico de variables de conteo.
- precision_modelo (asimetría = -0.48): distribución ligeramente sesgada hacia valores altos, con una cola izquierda de casos donde el modelo falla. La bimodalidad documentada en la sección 2 es más informativa que la asimetría global.

2. Análisis de Distribuciones de Variables

El análisis de distribuciones examina la forma en que los valores de cada variable se dispersan a lo largo de su rango de posibles valores. La identificación de la forma distribucional —si es simétrica, sesgada, bimodal o uniforme— tiene implicaciones directas para las decisiones de modelado, ya que muchos algoritmos asumen normalidad en las variables de entrada y las distribuciones con sesgo pronunciado pueden requerir transformaciones previas para satisfacer esos supuestos.

En el contexto del sistema Text-to-SQL, las distribuciones de las variables de complejidad SQL son particularmente informativas porque revelan cuál es la dificultad típica de las consultas que el sistema debe procesar. La distribución de `precision_modelo` es la más crítica, pues su forma determina si el modelo tiene un comportamiento consistente o si existen regímenes de operación cualitativamente distintos.

2.1 Distribución de Variables Numéricas Clave

2.1.1 Longitud de la Pregunta (caracteres)

La distribución de longitud de preguntas es aproximadamente normal con leve sesgo positivo (asimetría = 0.58), con media de 62.3 y mediana de 60.1 caracteres. La diferencia de 2.2 caracteres entre ambas medidas confirma una distribución casi simétrica con pocas preguntas muy largas. El 75% de las preguntas contiene menos de 78 caracteres, lo que confirma que el sistema procesará consultas relativamente breves la mayor parte del tiempo. Esta característica es favorable para la latencia del sistema, ya que las preguntas cortas generan prompts más compactos y reducen el tiempo de inferencia del LLM.

2.1.2 Número de JOINS en el SQL Generado

La distribución de `num_joins` es fuertemente asimétrica a la derecha (asimetría = 1.71), con una distribución discreta con pico pronunciado en cero. El análisis de frecuencias revela la siguiente estructura:

Núm. JOINS	0	1	2	3 – 4	5 +
Frecuencia absoluta	671	218	98	38	9
Frecuencia relativa	64.9%	21.1%	9.5%	3.7%	0.9%

El hecho de que el 64.9% de las consultas no requiera ningún JOIN implica que el dataset está desbalanceado a favor de consultas simples. Esta asimetría requiere una estrategia de evaluación diferenciada por subgrupo de complejidad para no sobreestimar el rendimiento global del modelo.

2.1.3 Precisión del Modelo — Distribución Bimodal

La distribución de `precision_modelo` es el hallazgo más relevante del análisis de distribuciones: presenta una distribución bimodal con dos modos claramente diferenciados alrededor de 0.72 y 0.91. Este

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

patrón no es un artefacto estadístico sino la firma empírica de dos regímenes de operación cualitativamente distintos del sistema Text-to-SQL.

Modo	Valor Aproximado	% de Observaciones	Tipo SQL Predominante
Modo alto (sistema preciso)	≈ 0.91	$\approx 60\%$	SIMPLE / MEDIUM
Modo bajo (sistema limitado)	≈ 0.72	$\approx 40\%$	COMPLEX / NESTED

La bimodalidad tiene implicación de diseño directa: el sistema debería incluir un clasificador de complejidad previo que identifique las consultas COMPLEX y NESTED y aplique automáticamente la estrategia de descomposición (DIN-SQL) para ese subgrupo, en lugar de usar la misma estrategia de generación para todas las consultas por igual.

2.2 Distribución de Variables Categóricas

Variable	Categorías	Distribución	Implicación
dominio	6	Académico 28% · Empresarial 22% · Deportes 16% · Geografía 14% · Finanzas 12% · Salud 8%	El dominio salud (8%) está subrepresentado. Requiere augmentación de datos.
tipo_sql	4	SIMPLE 35% · MEDIUM 30% · COMPLEX 22% · NESTED 13%	Desbalance que requiere SMOTE para las clases COMPLEX y NESTED.

3. Identificación de Correlaciones

El análisis de correlaciones cuantifica la fuerza y dirección de las relaciones lineales entre pares de variables numéricas mediante el coeficiente de correlación de Pearson (r), que toma valores en el intervalo $[-1, +1]$. Un valor positivo indica que las variables tienden a crecer juntas; uno negativo indica relación inversa; y un valor próximo a cero indica ausencia de relación lineal. Para el sistema Text-to-SQL, las correlaciones con `precision_modelo` son las más relevantes porque revelan empíricamente qué características del problema determinan el rendimiento del sistema y, en consecuencia, justifican las decisiones de diseño de la arquitectura propuesta.

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

3.1 Matriz de Correlaciones de Pearson

Variable	tokens	n.tablas	n.cond.	n.joins	long.sql	tiempo_ms	precision
long_pregunta	0.87	0.18	0.22	0.14	0.31	0.19	-0.21
tokens_pregunta	—	0.21	0.24	0.17	0.28	0.16	-0.18
num_tablas		—	0.52	0.58	0.74	0.44	-0.41
num_condiciones			—	0.44	0.61	0.38	-0.38
num_joins				—	0.68	0.51	-0.54
longitud_sql					—	0.48	-0.44
tiempo_ms						—	-0.29
precision_modelo							—

Nota: Color azul = correlación positiva fuerte ($|r| \geq 0.50$). Color salmón = correlación negativa significativa ($r \leq -0.38$). Ambos colores indican relaciones estadísticamente relevantes para el diseño del sistema.

3.2 Análisis de las Correlaciones más Relevantes

Par de Variables	r de Pearson	Interpretación e Implicación para el Sistema
num_joins ↔ precision_modelo	-0.54	Correlación negativa más fuerte con la precisión. A mayor número de JOINS, menor precisión del LLM. Justifica empíricamente la estrategia RAG con schema linking: restringir el contexto a las tablas relevantes mitiga este efecto documentado.
num_tablas ↔ longitud_sql	0.74	Correlación positiva fuerte. Más tablas en la consulta produce SQL más largo. Predictor útil del tiempo de generación y la complejidad computacional del proceso.
num_tablas ↔ num_joins	0.58	Correlación esperada: más tablas implica más operaciones JOIN. Ambas variables capturan la misma dimensión de complejidad estructural y son parcialmente redundantes.

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

longitud_sql ↔ precision_modelo	-0.44	SQL más largo correlaciona con menor precisión. Evidencia adicional de que la complejidad del SQL dificulta la generación correcta por parte del LLM.
longitud_sql ↔ tiempo_ms	0.48	Las consultas que generan SQL más largo tardan más en procesarse. Justifica el umbral de latencia SMART de ≤ 10 segundos como función de la complejidad de la consulta.
longitud_pregunta ↔ tokens_pregunta	0.87	Correlación casi perfecta esperada: más caracteres implica más palabras. Indica que una de las dos variables puede eliminarse por redundancia sin pérdida de información.

4. Detección de Valores Atípicos (Outliers)

La detección de valores atípicos es una de las etapas más críticas del análisis exploratorio porque estos valores pueden tener dos naturalezas completamente distintas con implicaciones opuestas: pueden ser errores de medición o registro que deben eliminarse o corregirse antes del modelado, o pueden ser observaciones genuinas y científicamente valiosas que revelan casos extremos reales del problema. Distinguir entre ambas naturalezas requiere juicio de dominio además de criterios estadísticos.

Se emplean dos métodos complementarios para la detección. El método del Rango Intercuartílico (IQR) clasifica como outlier todo valor que cae fuera del intervalo $[Q1 - 1.5 \cdot IQR, Q3 + 1.5 \cdot IQR]$; es el método más robusto porque no depende de supuestos distribucionales. El método del Z-score clasifica como outlier todo valor con $|z| > 3$, siendo adecuado para distribuciones aproximadamente normales.

4.1 Resumen de Outliers por Variable

Variable	IQR	Z-score	% Total	Límite inferior	Límite superior	Decisión de tratamiento
longitud_pregunta	28	12	2.7%	< 1	≥ 139 chars	Conservar — preguntas largas son válidas en el dominio
tokens_pregunta	22	9	2.1%	< 4	≥ 22 tokens	Conservar — consultas extensas son legítimas
num_tablas	14	6	1.4%	N/A	≥ 6 tablas	Conservar — esquemas complejos son casos reales

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

num_condiciones	18	8	1.7%	N/A	≥ 6 cond.	Conservar — filtros múltiples son legítimos
num_joins	21	9	2.0%	N/A	≥ 4 joins	Analizar — revisar consultas con ≥ 4 JOINS
longitud_sql	41	18	4.0%	< 22	≥ 362 chars	Analizar — SQL > 350 chars: verificar validez sintáctica
tiempo_respuesta_ms	86	38	8.7%	N/A	≥ 9,200 ms	Transformar — aplicar log1p antes del modelado
precision_modelo	12	5	1.2%	< 0.43	N/A	Conservar — casos difíciles son informativos

4.2 Análisis Específico del Outlier Principal: tiempo_respuesta_ms

La variable tiempo_respuesta_ms concentra el mayor porcentaje de outliers (8.7%) y merece un análisis específico dado que sus valores extremos tienen un patrón no aleatorio: se concentran exclusivamente en consultas de tipo NESTED. Esta característica confirma que no son errores de medición sino consultas legítimamente difíciles que causan timeouts del servidor de inferencia.

Característica	Consultas Normales	Outliers (> 9,200 ms)	Diferencia
Tipo SQL predominante	SIMPLE / MEDIUM	100% NESTED	Segregación perfecta
Tiempo mediano	2,680 ms	24,800 ms	9.3 veces más lento
Núm. de JOINS (prom.)	0.8	3.4	4.25 veces más JOINS
Tratamiento aplicado	Log1p(x)	Log1p(x) conservado	Asimetría: 3.82 → 0.38

Decisión final respecto a los outliers de tiempo_ms: CONSERVAR con transformación log1p. Eliminar estos casos sesgaría el análisis al excluir los escenarios más exigentes del sistema, que son precisamente los más importantes para evaluar el rendimiento en producción y diseñar estrategias de optimización.

5. Análisis de Valores Faltantes (Missing Values)

El análisis de valores faltantes examina la magnitud y el patrón de datos ausentes en el dataset. La magnitud determina si la estrategia de manejo apropiada es la imputación (para tasas bajas, generalmente < 10%) o la eliminación de observaciones (para tasas altas, aunque con el riesgo de perder información valiosa). El patrón de ausencia es igualmente crítico: los datos pueden faltar completamente al azar (MCAR — Missing Completely At Random), al azar condicionado a otras variables observables (MAR — Missing At Random), o de manera sistemática relacionada con el propio valor faltante (MNAR — Missing Not At Random). Cada mecanismo requiere estrategias de tratamiento metodológicamente distintas.

5.1 Resumen de Valores Faltantes

Variable	N Faltantes	% Faltantes	Mecanismo	Estrategia
tiempo_respuesta_ms	43	4.2%	MAR	Imputación por mediana del grupo (dominio × tipo_sql)
precision_modelo	29	2.8%	MAR	Imputación por mediana del grupo (dominio × tipo_sql)
longitud_pregunta	0	0.0%	—	Sin tratamiento necesario
tokens_pregunta	0	0.0%	—	Sin tratamiento necesario
num_tablas	0	0.0%	—	Sin tratamiento necesario
num_condiciones	0	0.0%	—	Sin tratamiento necesario
num_joins	0	0.0%	—	Sin tratamiento necesario
longitud_sql	0	0.0%	—	Sin tratamiento necesario
dominio	0	0.0%	—	Sin tratamiento necesario
tipo_sql	0	0.0%	—	Sin tratamiento necesario

5.2 Determinación del Mecanismo de Ausencia

La validación del mecanismo MAR se realizó mediante análisis de la distribución de valores faltantes en función de las variables categóricas del dataset. Los resultados confirman que los faltantes no

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL”	
---	---	--

ocurren al azar sino de manera concentrada en subgrupos específicos, lo cual es la definición estadística del mecanismo MAR.

Variable categórica	Categoría con mayor faltante	% faltantes en esa categ.	% faltantes en resto	Chi- cuadrado	p- valor
dominio	salud	7.8%	3.6% promedio	$\chi^2 = 14.2$	< 0.01
tipo_sql	NESTED	6.1%	3.1% promedio	$\chi^2 = 18.4$	< 0.001

Los faltantes están estadísticamente asociados con dominio='salud' y tipo_sql='NESTED' ($p < 0.001$). Esto confirma el mecanismo MAR: corresponden a consultas que causaron timeouts del servidor durante la ejecución de consultas NESTED complejas en el dominio salud, no errores aleatorios de registro. La imputación por mediana del subgrupo (dominio $\times$ tipo_sql) es metodológicamente correcta bajo este mecanismo.

5.3 Estrategia de Imputación Implementada

Dado el mecanismo MAR confirmado estadísticamente, se aplica imputación por mediana del subgrupo definido por el cruce de las dos variables predictoras de la ausencia (dominio $\times$ tipo_sql). Este método preserva la distribución local de cada combinación de subgrupo, a diferencia de la imputación global que introduciría sesgo al mezclar subpoblaciones con distribuciones de rendimiento muy diferentes.

Subgrupo (ejemplo)	Mediana tiempo_ms	Mediana precisión	Justificación
académico $\times$ SIMPLE	1,680 ms	0.912	Consultas simples en dominio académico: rápidas y precisas. Imputación global distorsionaría este subgrupo.
salud $\times$ NESTED	11,420 ms	0.631	Consultas anidadas en dominio salud: lentas y menos precisas. La mediana global (3,814 ms) introduciría sesgo severo.
deportes $\times$ MEDIUM	2,980 ms	0.848	Rendimiento intermedio. Imputación diferenciada mantiene la coherencia estadística del subgrupo.

6. Hallazgos Principales e Implicaciones para el Modelado

El análisis exploratorio de datos revela seis hallazgos que se traducen directamente en decisiones concretas del pipeline de preparación de datos y en la arquitectura del sistema Text-to-SQL. Estos hallazgos no son observaciones descriptivas abstractas: cada uno genera una acción verificable que puede ser implementada y evaluada de manera objetiva.

#	Hallazgo	Implicación y Acción Derivada
1	Distribución bimodal de precision_modelo	El sistema opera en dos regímenes distintos: alta precisión para consultas simples (modo ≈ 0.91) y precisión reducida para consultas complejas (modo ≈ 0.72). Implicación: crear la variable engineered 'regime_label' como target binario para un clasificador auxiliar de dificultad de consulta.
2	Correlación negativa JOINS–precisión ($r = -0.54$)	Evidencia empírica directa de que la complejidad SQL degrada el rendimiento del LLM. Implicación: justifica la arquitectura RAG con schema linking para pre-filtrar las tablas relevantes y reducir la complejidad del contexto enviado al LLM.
3	Missing values MAR confirmado ($p < 0.001$)	Los faltantes en tiempo_ms y precision_modelo están asociados con dominio='salud' y tipo_sql='NESTED'. Implicación: la imputación por mediana del subgrupo (dominio $\times$ tipo_sql) es la estrategia estadísticamente correcta.
4	Outliers de tiempo_ms (8.7%, asimetría = +3.82)	Los valores extremos corresponden a consultas NESTED legítimas con tiempos de 25–45 segundos. Implicación: transformación log1p antes del modelado; conservar las observaciones para el análisis de rendimiento en el subgrupo más difícil.
5	Desbalance en tipo_sql (NESTED=13%, SIMPLE=35%)	La clase de mayor dificultad y mayor interés para el sistema está subrepresentada en una proporción de 2.7 $\times$. Implicación: aplicar SMOTE semántico en el espacio de embeddings para oversampling de COMPLEX y NESTED.
6	Correlación longitud_sql–tiempo_ms ($r = 0.48$)	Las consultas que generan SQL más largo son más lentas de procesar. Implicación: el umbral SMART de ≤ 10 segundos debe monitorearse específicamente en el subgrupo de consultas con longitud_sql > 250 caracteres.

6.1 Conclusiones

El análisis exploratorio de datos confirma que el dataset Spider-subset es adecuado para el entrenamiento y evaluación del sistema Text-to-SQL propuesto, con las siguientes condiciones que deben ser atendidas en el pipeline de preparación de datos:

- La transformación log1p de tiempo_respuesta_ms es obligatoria antes del modelado debido a la asimetría extrema (+3.82) que viola los supuestos de normalidad de la mayoría de algoritmos de regresión y aumentaría innecesariamente la influencia de los outliers en el proceso de entrenamiento.
- La evaluación del sistema debe realizarse de manera diferenciada por tipo_sql (SIMPLE, MEDIUM, COMPLEX, NESTED) para evitar que el alto rendimiento en consultas simples enmascare el bajo rendimiento en las complejas, que son las de mayor relevancia para demostrar el valor del sistema.
- La variable longitud_pregunta y tokens_pregunta tienen correlación de Pearson de 0.87, por lo que una de las dos puede eliminarse sin pérdida de información relevante para reducir la multicolinealidad en modelos lineales.
- El dominio 'salud' requiere atención especial: presenta menor representación (8%), mayor tasa de faltantes (7.8%) y menor precisión del modelo (−4 pp vs. media), lo que lo convierte en el dominio con mayor área de mejora potencial y mayor necesidad de augmentación de datos.

Referencias Bibliográficas

- Yu, T., Zhang, R., Yang, K., Yasunaga, M., Wang, D., Li, Z., ... & Radev, D. (2018). Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. Proceedings of EMNLP 2018. arXiv: 1809.08887.
- Li, J., Hui, B., Qu, G., Yang, J., Li, B., Li, B., ... & Cheng, H. (2023). Can LLM Already Serve as A Database Interface? A Big Bench for Large-Scale Database Grounded Text-to-SQL. Advances in NeurIPS 2023. arXiv: 2305.03111.
- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley Publishing Company. ISBN 978-0-201-07616-5.
- Rubin, D. B. (1976). Inference and missing data. Biometrika, 63(3), 581–592. DOI: 10.1093/biomet/63.3.581.
- Pourreza, M., & Rafiei, D. (2023). DIN-SQL: Decomposed In-Context Learning of Text-to-SQL with Self-Correction. Advances in NeurIPS 2023, 36. arXiv: 2304.11015.