



UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO

MAESTRÍA EN INTELIGENCIA ARTIFICIAL

ASIGNATURA:

PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL

ACTIVIDAD:

REFLEXIÓN ÉTICA DEL PROYECTO

IDENTIFICACIÓN DE RIESGOS ÉTICOS, ANÁLISIS DE STAKEHOLDERS E IMPACTO SOCIAL

AUTORES:

CABRERA PARRALES JOEL DAVID

SÁNCHEZ ARÉVALO ANÍBAL ANDRÉS

TUTOR:

MG. ALEXANDRA J. ARCINIEGAS C.

SAMBORONDÓN – ECUADOR

ABRIL – 2026

Resumen

El presente documento desarrolla la reflexión ética del Proyecto Integrador en Inteligencia Artificial titulado "Análisis Comparativo de Técnicas de IA para Text-to-SQL con Visualización Automática", construido sobre el benchmark Spider (Yu et al., 2018) y materializado en un clasificador Random Forest auxiliar de dificultad de consultas SQL. La actividad se enmarca dentro del calendario académico de elaboración del proyecto, comprendido entre el 21 de marzo y el 15 de mayo de 2026, y corresponde específicamente a la sexta semana del cronograma entre el 25 de abril y el 1 de mayo, posición intermedia que el equipo reconoce como deliberada: la reflexión ética se ubica una vez consolidados los hallazgos empíricos del modelo y antes de las fases finales de simulación de escenarios críticos y cierre, de modo que pueda articular ambos extremos del proyecto.

La reflexión se organiza en tres bloques alineados con la rúbrica de la asignatura: identificación y caracterización de riesgos éticos contextualizados al caso de estudio, análisis de stakeholders con sus valores e intereses en juego, y evaluación del impacto social del sistema junto con los lineamientos de responsabilidad asumidos por el equipo investigador. El análisis articula la evidencia empírica obtenida en fases previas del proyecto en particular las disparidades detectadas por longitud de pregunta (Disparity Ratio = 0,499), por presencia de cláusulas JOIN (DR = 0,674) y por dominio de base de datos (DR = 0,620), todas por debajo de la regla del 80% con marcos normativos y académicos contemporáneos: la Ley Europea de Inteligencia Artificial (Reglamento (UE) 2024/1689), la NIST AI Risk Management Framework 1.0 (NIST, 2023), la taxonomía de sesgos de Mehrabi et al. (2021) y la categorización de riesgos algorítmicos de Barocas et al. (2019). Las conclusiones del documento sostienen que el sistema, en su estado actual, constituye un prototipo académico que requiere mitigaciones explícitas antes de cualquier consideración de despliegue productivo, y que la responsabilidad del equipo se materializa en compromisos medibles de transparencia, supervisión humana, monitoreo continuo y limitación intencional del alcance.

1. Introducción

La adopción acelerada de sistemas de inteligencia artificial en entornos organizacionales y de servicio público ha consolidado la ética como una dimensión inseparable del diseño técnico. Esta exigencia se intensifica cuando los sistemas median el acceso a la información, automatizan decisiones que históricamente correspondían a personas o establecen filtros entre los usuarios y los datos críticos de una organización. El proyecto desarrollado por el equipo un sistema conversacional Text-to-SQL con visualización automática orientado a usuarios sin conocimiento técnico en SQL se ubica con claridad en esta categoría: opera como interfaz cognitiva entre la pregunta natural del usuario y la base de datos

relacional, con potencial de transformar el acceso a la analítica empresarial y, en consecuencia, las relaciones de poder que ese acceso configura.

La reflexión ética que aquí se presenta no es un complemento decorativo del trabajo técnico desarrollado en fases anteriores. Es, por el contrario, una continuación lógica del diagnóstico de sesgo, robustez y generalización ya documentado en el Informe de Evaluación de Modelos y en el Informe Técnico de Evaluación Avanzada y Optimización. Las disparidades cuantificadas en aquellos documentos donde el modelo trataba sistemáticamente peor a usuarios con preguntas largas, consultas con JOIN y dominios subrepresentados no son fenómenos abstractos: son la materialización empírica de los riesgos éticos que este documento se propone caracterizar, contextualizar y, en la medida posible, mitigar.

La estructura del documento responde con precisión a los tres ejes definidos en la rúbrica de la actividad. El apartado 2 sitúa la actividad dentro del cronograma de ocho semanas del Proyecto Integrador, justificando su posición intermedia. El apartado 3 desarrolla la identificación de riesgos éticos en el caso de estudio, distinguiendo riesgos explícitos e implícitos y evaluando impactos diferenciales sobre grupos de usuarios. El apartado 4 corresponde al workshop de análisis de stakeholders, mapea actores directos, indirectos y reguladores e identifica conflictos de valores. El apartado 5 desarrolla el workshop de impacto social y responsabilidad, balancea beneficios y riesgos, distingue implicaciones de corto y largo plazo, y formula compromisos operativos del equipo. El apartado 6 cierra con conclusiones y la declaración formal de responsabilidad ética.

2. Cronograma del Proyecto Integrador

2.1. Periodo de elaboración y posición de la actividad

El Proyecto Integrador en Inteligencia Artificial se desarrolla durante un periodo de ocho semanas comprendido entre el sábado 21 de marzo de 2026 y el viernes 15 de mayo de 2026. Esta extensión temporal corresponde al calendario académico de la titulación y articula la entrega secuencial de las distintas fases que componen el ciclo completo de un proyecto de inteligencia artificial: desde la fundamentación bibliográfica hasta la simulación de escenarios críticos y la presentación final del trabajo.

La presente actividad Reflexión Ética del Proyecto se ubica en la sexta semana del cronograma. Una reflexión ética formulada antes de generar evidencia empírica del modelo carecería de sustento factual y se reduciría a una enumeración abstracta de riesgos genéricos; una reflexión formulada al final del proyecto perdería capacidad de operacionalización porque las decisiones de diseño ya estarían consolidadas. La ubicación intermedia permite que esta reflexión cumpla su función real: articular los hallazgos empíricos previos sesgos cuantificados, robustez frágil, sospecha de fuga de información con las decisiones que aún

quedan pendientes en las fases finales del cronograma, especialmente la simulación de escenarios críticos prevista para la séptima semana.

2.2. Cronograma detallado de fases

La Tabla 1 detalla la distribución de las fases del proyecto a lo largo de las ocho semanas, con sus rangos de fechas, los entregables asociados y la posición relativa de la presente actividad.

Sem.	Fechas	Fase	Entregable principal
1	21–27 marzo 2026	Definición y planificación	Cronograma, alcance, objetivos SMART
2	28 mar – 03 abr 2026	Estado del arte y recursos	Recursos y Estado del Arte
3	04–10 abril 2026	Análisis exploratorio	EDA del dataset Spider
4	11–17 abril 2026	Preparación de datos	Pipeline de preprocesamiento
5	18–24 abril 2026	Evaluación de modelos	Benchmarking comparativo
6	25 abr – 01 may 2026	Reflexión ética + Optimización	Reflexión Ética (este documento)
7	02–08 mayo 2026	Escenarios críticos	Workshop de simulación
8	09–15 mayo 2026	Cierre y presentación	Informe final consolidado

Tabla 1. Cronograma de ocho semanas del Proyecto Integrador en Inteligencia Artificial. Periodo total: 21/03/2026 – 15/05/2026. Elaboración propia.

2.3. Visualización de fases (diagrama de Gantt)

La Figura 1 representa el cronograma como diagrama de Gantt simplificado, donde cada fila corresponde a una fase del proyecto y las celdas pintadas indican las semanas de ejecución. La fase resaltada en color dorado señala la posición de la presente actividad dentro del calendario completo.

FASE / SEMANA	S1	S2	S3	S4	S5	S6	S7	S8
Definición y planificación								
Estado del arte y recursos								
Análisis exploratorio (EDA)								
Preparación de datos								
Evaluación de modelos								

FASE / SEMANA	S1	S2	S3	S4	S5	S6	S7	S8
Reflexión ética (actual)								
Optimización avanzada								
Escenarios críticos								
Cierre y presentación final								

Figura 1. Diagrama de Gantt del Proyecto Integrador. Las celdas en burdeos representan las fases ejecutadas; la celda en dorado destaca la actividad de Reflexión Ética abordada en el presente documento. Elaboración propia.

2.4. Articulación con las fases previas y posteriores

La reflexión ética toma como insumos directos los productos de las fases anteriores: el Estado del Arte aporta el marco bibliográfico actualizado sobre fairness y equidad algorítmica que sustenta los apartados conceptuales; el EDA proporciona la bimodalidad de precisión documentada y la distribución desigual de dominios; la fase de preparación de datos identifica las clases minoritarias hard y extra que recibieron data augmentation focalizado; la evaluación de modelos cuantifica los disparity ratios que constituyen la columna vertebral de la sección 3. Esta dependencia ascendente confirma que la reflexión ética no es una pieza opcional sino el corolario natural de un trabajo técnico previamente realizado con rigor.

De manera simétrica, la reflexión ética alimenta las fases posteriores. Los riesgos identificados en este documento se convierten en hipótesis de prueba para el workshop de escenarios críticos de la séptima semana, donde se evaluará empíricamente cómo el sistema responde ante perturbaciones y casos límite. Las estrategias de mitigación propuestas se incorporan al informe final consolidado de la octava semana como parte integral del trabajo entregado.

3. Identificación de Riesgos Éticos

3.1. Marco conceptual

La identificación de riesgos sigue la taxonomía propuesta por Mehrabi et al. (2021) en su revisión sistemática sobre sesgo y equidad en aprendizaje automático, complementada con las categorías operativas de la NIST AI Risk Management Framework 1.0 (NIST, 2023) y la clasificación de sistemas de IA por nivel de riesgo establecida en el Reglamento (UE) 2024/1689 sobre inteligencia artificial. Esta triangulación permite distinguir entre riesgos explícitos aquellos directamente atribuibles al diseño o al comportamiento observable del sistema y riesgos implícitos aquellos que emergen de la interacción del sistema con su contexto de uso, frecuentemente invisibles durante el desarrollo pero críticos en producción (Selbst et al., 2019).

Para la valoración de cada riesgo se adoptan tres dimensiones: probabilidad de ocurrencia, severidad del daño potencial y reversibilidad. Esta tríada está alineada con la metodología de evaluación de impacto algorítmico (Algorithmic Impact Assessment) recomendada por la AI Now Institute (Reisman et al., 2018) y refinada en marcos posteriores como el Canadian Directive on Automated Decision-Making.

3.2. Riesgos éticos identificados

La Tabla 2 sintetiza los siete riesgos principales detectados a partir del análisis técnico previo del proyecto, su naturaleza, evidencia empírica de respaldo y nivel de criticidad asignado.

#	Riesgo ético	Tipo	Evidencia / Fuente	Criticidad
R1	Sesgo por longitud de pregunta	Explícito	DR = 0,499 (Informe Técnico, §1.2)	Alta
R2	Sesgo por estructura SQL (JOIN)	Explícito	DR = 0,674 (Informe Técnico, §1.2)	Alta
R3	Sesgo por dominio de base de datos	Explícito	DR = 0,620 (Informe Técnico, §1.2)	Alta
R4	Opacidad y falta de explicabilidad	Implícito	Random Forest 200 árboles, 85 features	Media
R5	Riesgos de privacidad y exposición de datos	Implícito	Acceso conversacional a BD relacional	Alta
R6	Sustitución de criterio humano experto	Implícito	Visualización automática + delegación	Media
R7	Inseguridad SQL y posibilidad de ejecución indebida	Explícito	Generación abierta sin PICARD	Alta

Tabla 2. Matriz consolidada de riesgos éticos del proyecto Text-to-SQL. DR: Disparity Ratio. Elaboración propia a partir de los hallazgos técnicos previos del Grupo 1.

3.3. Análisis de impacto diferencial por grupo de usuarios

Los siete riesgos identificados no se distribuyen homogéneamente entre los usuarios del sistema. El análisis cruzado de las disparidades cuantificadas en el Informe Técnico con las personas usuarias del sistema permite identificar cuatro categorías diferenciales de impacto.

3.3.1. Usuarios primarios Personal de gerencia y operaciones sin formación SQL

Constituyen el público objetivo declarado del sistema. Reciben los beneficios principales acceso conversacional a la información, autonomía analítica, reducción de la dependencia del área de tecnología, pero también asumen los riesgos derivados de la generación de SQL incorrecto sin capacidad técnica para detectarlo. La asimetría informativa entre el sistema y este perfil de usuario es el factor que más amplifica el riesgo ético: una respuesta plausible pero errónea puede inducir decisiones de negocio incorrectas sin que el usuario disponga de los mecanismos para verificarla. Esta categoría coincide con lo que la literatura identifica como "automation bias" (Goddard, Roudsari & Wyatt, 2012), la tendencia documentada de los usuarios a confiar excesivamente en sistemas automatizados incluso cuando la salida es incorrecta.

3.3.2. Usuarios vulnerables Hablantes de español como segunda lengua y usuarios con estilos verbales atípicos

La evidencia empírica del proyecto es contundente: las preguntas largas obtienen un Accuracy de 0,409 frente a 0,821 de las cortas (Informe Técnico, §1.2), una brecha de 41,2 puntos porcentuales. Este patrón implica que el sistema atiende sistemáticamente peor a quienes formulan sus consultas con mayor extensión, prolijidad o redundancia léxica características que correlacionan empíricamente con perfiles de usuario menos familiarizados con la formulación canónica de preguntas analíticas, hablantes de español que aprenden a interactuar con tecnologías originalmente desarrolladas en inglés, o usuarios con estilos cognitivos divergentes. Tratar a estos usuarios como un grupo vulnerable no es una concesión retórica: es la consecuencia lógica de la evidencia.

3.3.3. Sujetos indirectamente afectados Personas representadas en la base de datos

Cuando el sistema opera sobre bases de datos que contienen información personal empleados, clientes, pacientes, estudiantes, las personas representadas en esos registros se convierten en sujetos indirectamente afectados sin haber consentido el uso del sistema ni tener visibilidad sobre las consultas que se ejecutan. Aun cuando el sistema solo realice operaciones de lectura, el riesgo de re-identificación a través de cruces de campos, la generación de inferencias no autorizadas y la asimetría entre quienes consultan y quienes son consultados configuran un escenario de impacto invisible que la literatura sobre privacidad diferencial (Dwork & Roth, 2014) y minimización de datos (Reglamento (UE) 2016/679, art. 5) obliga a tratar con prioridad.

3.3.4. Usuarios excluidos Personas con discapacidad y usuarios sin acceso digital

El sistema, en su forma actual de prototipo, asume capacidades visuales para interpretar visualizaciones automáticas, dominio del español escrito y acceso a infraestructura computacional con conectividad. Cualquier despliegue institucional debe contemplar adaptaciones de accesibilidad descripción textual de

gráficos, compatibilidad con lectores de pantalla, equivalentes operativos por voz so pena de profundizar las brechas digitales preexistentes en el contexto ecuatoriano (UNESCO, 2022).

3.4. Estrategias de mitigación priorizadas

A partir de los riesgos identificados se definieron cinco líneas de mitigación, ordenadas por costo de implementación y efecto esperado sobre la población usuaria. Estas estrategias extienden y operacionalizan las recomendaciones técnicas formuladas en los informes previos del proyecto, y se cronogramificarán para ejecutarse parcialmente en la séptima semana (workshop de escenarios críticos) y se documentarán íntegramente en el informe final de la octava semana.

- **Mitigación de sesgos cuantificados (R1-R3):** aplicar reweighting por longitud y por dominio, ampliar el corpus mediante back-translation focalizada en preguntas largas y dominios subrepresentados, y reemplazar la representación TF-IDF por embeddings contextuales (CodeBERT) que demostraron mejor generalización cross-domain en la literatura (Feng et al., 2020).
- **Transparencia y explicabilidad (R4):** incorporar un módulo de explicación local mediante SHAP (Lundberg & Lee, 2017) que muestre las features más influyentes en cada predicción, y publicar una "model card" (Mitchell et al., 2019) accesible para los usuarios finales con métricas desagregadas por subgrupo.
- **Privacidad y minimización (R5):** implementar control granular de acceso por roles a nivel de tabla y columna, registro auditable de todas las consultas ejecutadas, y aplicación del principio de minimización de datos del Reglamento (UE) 2016/679 mediante enmascaramiento automático de columnas sensibles cuando no exista justificación expresa.
- **Supervisión humana (R6):** introducir un mecanismo de "human-in-the-loop" que solicite confirmación explícita del usuario para consultas etiquetadas como hard o extra-hard, y mantener el SQL generado siempre visible y editable antes de la ejecución, alineándose con el requisito de supervisión humana del Reglamento (UE) 2024/1689.
- **Seguridad de ejecución SQL (R7):** integrar PICARD (Scholak et al., 2021) para decodificación restringida que verifique la validez gramatical durante la generación, restringir la lista blanca de operaciones a SELECT exclusivamente, prohibir DDL y DML por construcción, y mantener un sandbox de ejecución con timeouts y límites de filas.

4. Workshop de Stakeholders y Valores

4.1. Metodología de mapeo

El mapeo de stakeholders adoptó la metodología propuesta por Friedman, Hendry y Borning (2017) en el marco del Value Sensitive Design (VSD), enfoque metodológico que sostiene que los valores de los actores afectados deben ser identificados y operacionalizados explícitamente en el ciclo de vida del sistema. Se categorizaron cuatro tipos de stakeholders siguiendo la distinción del VSD: directos (quienes interactúan con el sistema), indirectos (quienes son afectados sin interactuar), reguladores (quienes definen las reglas del entorno) y la sociedad civil (afectados invisibles a los que la literatura más reciente, Birhane et al., 2022, ha denominado "stakeholders olvidados").

4.2. Mapa de stakeholders del proyecto

La Tabla 3 presenta el mapa exhaustivo de stakeholders identificados, sus intereses primarios, los valores en juego y las posibles tensiones que los enfrentan a otros actores.

Tipo	Stakeholder	Interés primario	Valor en juego
Directo	Personal de gerencia y operaciones	Acceso autónomo y rápido a información	Autonomía, productividad
Directo	Equipo de TI / DBAs	Mantener control e integridad de la BD	Seguridad, integridad
Directo	Equipo de desarrollo del sistema	Mejora continua y reproducibilidad	Excelencia técnica, integridad académica
Indirecto	Empleados representados en datos	Privacidad, no discriminación	Privacidad, dignidad
Indirecto	Clientes representados en datos	Confidencialidad, uso adecuado	Privacidad, autodeterminación
Indirecto	Áreas no técnicas (RRHH, Legal, Compliance)	Cumplimiento normativo y reputacional	Legalidad, transparencia
Regulador	Autoridad de Protección de Datos (Ec.)	Cumplimiento de la LOPDP	Legalidad, protección de derechos
Regulador	Audidores externos / SRI / Org. control	Trazabilidad y rendición de cuentas	Accountability, integridad

Tipo	Stakeholder	Interés primario	Valor en juego
Regulador	UEES Comité Académico	Rigor metodológico e integridad investigativa	Honestidad académica
Sociedad	Usuarios con accesibilidad reducida	Acceso equitativo a la herramienta	Inclusión, equidad
Sociedad	Comunidad académica de IA	Reproducibilidad y avance del conocimiento	Transparencia científica
Sociedad	Población general	No amplificación de desigualdades digitales	Justicia social

Tabla 3. Mapa de stakeholders del proyecto Text-to-SQL agrupados por tipo de relación con el sistema.
Elaboración propia bajo el marco Value Sensitive Design (Friedman et al., 2017).

4.3. Identificación de valores y conflictos

Los valores que sostienen los intereses de los doce stakeholders mapeados no convergen automáticamente. La materialización del proyecto exige reconocer las tensiones reales entre ellos y tomar decisiones explícitas que privilegien unos valores sobre otros en escenarios concretos. Las tres tensiones más relevantes son:

4.3.1. Autonomía del usuario versus seguridad de los datos

El interés del usuario primario se traduce en máxima libertad de exploración: cualquier pregunta, cualquier vista, cualquier cruce. El interés del equipo de TI y de los reguladores se traduce en lo opuesto: restricciones, listas blancas, límites de filas, enmascaramientos. La resolución técnica de esta tensión, según el principio de "least privilege" articulado en el NIST Cybersecurity Framework (NIST, 2024), implica diseñar el sistema con seguridad por defecto y abrir progresivamente capacidades a medida que se acumula evidencia de uso responsable, no a la inversa.

4.3.2. Eficiencia operativa versus equidad algorítmica

Las disparidades documentadas en el Informe Técnico DR = 0,499 por longitud, 0,674 por JOIN, 0,620 por dominio evidencian que el modelo es más eficiente para los casos mayoritarios y menos justo con los minoritarios. Optimizar el sistema para mejorar el promedio puede ampliar la brecha. Esta tensión se resuelve, siguiendo a Selbst et al. (2019), no eligiendo una métrica única sino monitoreando simultáneamente desempeño promedio y desempeño en el peor subgrupo, e introduciendo mecanismos de mitigación explícita cuando el segundo se aleja sistemáticamente del primero.

4.3.3. Innovación académica versus integridad investigativa

El equipo investigador enfrenta la tensión entre presentar resultados optimistas que justifiquen el proyecto y reportar honestamente las limitaciones detectadas, en particular la sospecha fundada de data leakage discutida en el Informe de Evaluación de Modelos. La elección del equipo reportar abiertamente el leakage, dimensionar su impacto y proponer una reformulación de la tarea es la única coherente con la integridad investigativa que la UEES exige a sus tesis, y se documenta aquí como acto deliberado de responsabilidad académica.

4.4. Priorización de actores clave

La priorización adopta la matriz de Mendelow (1991), que cruza el nivel de poder de cada actor sobre el éxito del proyecto con el nivel de interés que tiene en sus resultados. La Tabla 4 muestra la priorización resultante.

Cuadrante	Estrategia	Stakeholders del proyecto
Alto poder + Alto interés	Gestión cercana y comunicación constante	Tutora UEES, Equipo de desarrollo
Alto poder + Bajo interés	Mantener satisfechos	Comité Académico UEES
Bajo poder + Alto interés	Mantener informados	Usuarios primarios, comunidad académica
Bajo poder + Bajo interés	Monitoreo mínimo	Población general, sociedad civil amplia

Tabla 4. Matriz de priorización de stakeholders según poder e interés (Mendelow, 1991). Elaboración propia.

Es importante observar que la matriz tradicional concentra atención en actores con poder formal y, por construcción, tiende a relegar a los stakeholders más vulnerables. Por esta razón, el equipo adopta una corrección consciente al marco: los usuarios indirectos representados en las bases de datos que carecen de poder formal sobre el sistema, pero soportan las consecuencias de su funcionamiento se incorporan al cuadrante de gestión cercana mediante la implementación de los mecanismos de privacidad descritos en el apartado 3.4, no por su poder sino por la severidad del impacto que reciben (Birhane et al., 2022).

5. Workshop de Impacto Social y Responsabilidad

5.1. Beneficios sociales del sistema propuesto

Una evaluación ética honesta debe contemplar tanto los riesgos como los beneficios potenciales que el sistema aporta cuando opera correctamente. Ignorar los beneficios conduce a una postura paralizante;

ignorar los riesgos conduce a una postura imprudente. El balance riguroso de ambos es la única posición sostenible (Floridi et al., 2018).

Los beneficios sociales del sistema, contextualizados al ámbito ecuatoriano y al perfil de usuarios objetivo, son cuatro:

- **Democratización del acceso a la analítica de datos.** Las pequeñas y medianas empresas ecuatorianas, que componen la mayoría del tejido productivo del país, históricamente carecen de equipos de analytics dedicados. Un sistema Text-to-SQL accesible reduce esta brecha y permite que decisiones gerenciales se sustenten en evidencia empírica antes que en intuición.
- **Reducción de la carga operativa del personal técnico.** Las áreas de TI dedican una proporción significativa de su tiempo a atender consultas ad-hoc de áreas de negocio. Automatizar la generación de SQL para preguntas estructuralmente sencillas libera capacidad técnica para problemas que sí exigen criterio experto, alineándose con el principio de "augmentation over automation" (Daugherty & Wilson, 2018).
- **Aceleración de los ciclos de decisión.** La latencia entre formulación de una pregunta de negocio y obtención de la respuesta se reduce en órdenes de magnitud, lo que mejora la capacidad organizacional de respuesta ante cambios de mercado.
- **Aporte a la formación de capacidades en IA en el contexto local.** El proyecto, al ser desarrollado dentro de la UEES y publicado con apertura metodológica, contribuye al ecosistema académico ecuatoriano de inteligencia artificial y constituye material de referencia para futuras cohortes.

5.2. Riesgos sociales y daños potenciales

Los riesgos sociales se distinguen de los riesgos técnicos identificados en el apartado 3 en que su materialización requiere la mediación del contexto social y temporal. Aun cuando el sistema funcione correctamente desde una perspectiva técnica, su impacto sobre las dinámicas sociales puede ser negativo. Cuatro riesgos sociales principales se identifican:

- **Amplificación de desigualdades en el acceso a la información.** Si el sistema se desplegara únicamente en áreas con conectividad y formación digital, ampliaría la brecha entre quienes ya disponen de información y quienes no.
- **Dependencia tecnológica y pérdida de competencias.** La automatización del análisis puede inducir, en plazos largos, una pérdida progresiva de las competencias analíticas que el sistema reemplaza, fenómeno conocido como "deskilling" en la literatura sobre tecnología y trabajo (Carr, 2014).

- **Concentración de poder informacional.** El proveedor del sistema acumula, mediante los logs de uso, conocimiento sobre las preguntas que las organizaciones formulan y, por extensión, sobre sus prioridades estratégicas. Esta asimetría exige mecanismos contractuales y técnicos de no apropiación.
- **Desplazamiento de la responsabilidad.** Cuando una decisión organizacional incorrecta se origina en una respuesta del sistema, la atribución de responsabilidad se difumina: ¿el usuario que formuló la pregunta, el equipo que diseñó el sistema, la organización que lo desplegó? Esta dilución es uno de los problemas centrales de la ética de IA (Matthias, 2004; Santoni de Sio & Mecacci, 2021).

5.3. Implicaciones a corto y largo plazo

La distinción temporal entre implicaciones inmediatas y diferidas es necesaria porque los marcos de mitigación adecuados para cada plazo son distintos. La Tabla 5 organiza el análisis temporal con referencia explícita al cronograma del proyecto: las implicaciones de corto plazo deben atenderse antes del cierre del 15 de mayo de 2026; las de medio plazo corresponden al periodo posterior a la entrega y a un eventual despliegue piloto; las de largo plazo configuran el horizonte de sostenibilidad del sistema.

Plazo	Implicación	Tipo
Corto plazo (semanas 7-8 del cronograma)	Errores de SQL generado en consultas complejas	Operativo
Corto plazo (semanas 7-8 del cronograma)	Frustración de usuarios con preguntas largas (sesgo R1)	Experiencia
Corto plazo (semanas 7-8 del cronograma)	Riesgos de privacidad por consultas no auditadas	Privacidad
Medio plazo (post-cierre, 6-24 meses)	Sesgos amplificados al integrar más dominios sin recalibración	Equidad
Medio plazo (post-cierre, 6-24 meses)	Dependencia operativa del sistema sin plan de contingencia	Resiliencia
Medio plazo (post-cierre, 6-24 meses)	Drift del modelo respecto a esquemas que evolucionan	Mantenimiento
Largo plazo (>24 meses)	Pérdida de competencias analíticas internas (deskilling)	Capital humano
Largo plazo (>24 meses)	Reconfiguración del rol del personal de TI	Organización

POSTGRADO MAESTRÍA EN INTELIGENCIA ARTIFICIAL	“REFLEXIÓN ÉTICA DEL PROYECTO”	UEES Universidad Espíritu Santo
--	--------------------------------	---------------------------------------

Plazo	Implicación	Tipo
Largo plazo (>24 meses)	Impacto sobre la cultura organizacional de toma de decisiones	Cultura

Tabla 5. Implicaciones a corto, medio y largo plazo del despliegue del sistema, con referencia al cronograma del Proyecto Integrador. Elaboración propia.

5.4. Responsabilidad en la toma de decisiones automatizadas

El Reglamento (UE) 2024/1689 sobre inteligencia artificial define obligaciones específicas para sistemas que operan en contextos de alto riesgo. Aunque el prototipo desarrollado no se encuadra formalmente en esa categoría no opera sobre infraestructuras críticas, no toma decisiones que afecten derechos fundamentales en el sentido restringido del Reglamento, el equipo investigador asume voluntariamente sus principios operativos como criterio de excelencia. Estos principios se traducen en cuatro compromisos concretos.

5.4.1. Supervisión humana significativa

El sistema es deliberadamente diseñado como herramienta de asistencia, no de sustitución. El SQL generado se muestra siempre al usuario antes de la ejecución, las visualizaciones se acompañan de la consulta subyacente, y las decisiones de negocio derivadas permanecen bajo la autoridad del responsable humano. Este compromiso responde al artículo 14 del Reglamento (UE) 2024/1689 y a los principios articulados por la Comisión Europea de Alto Nivel en Ética de IA (HLEG-AI, 2019).

5.4.2. Trazabilidad y rendición de cuentas

Toda interacción con el sistema queda registrada con timestamp, usuario, pregunta original, SQL generado, resultado de ejecución y eventual edición humana. Este registro auditable permite la reconstrucción de cualquier decisión cuestionada y constituye el sustrato técnico de la rendición de cuentas. El registro se conserva durante el período mínimo exigido por la normativa ecuatoriana (Ley Orgánica de Protección de Datos Personales, Asamblea Nacional del Ecuador, 2021) y se destruye automáticamente al expirar.

5.4.3. Transparencia hacia el usuario final

El sistema declara explícitamente sus limitaciones conocidas mediante una "model card" (Mitchell et al., 2019) accesible desde la interfaz: tipos de consultas en las que rinde mejor, subgrupos donde se ha detectado menor desempeño, métricas de equidad por variable sensible. La transparencia no es un complemento estético: es el único mecanismo que permite al usuario calibrar adecuadamente su confianza en cada respuesta.

5.4.4. Mejora continua y monitoreo

Las métricas de equidad por subgrupo se monitorean continuamente en producción. Se establecen umbrales de alerta automática Disparity Ratio inferior a 0,80, F1 macro por debajo de 0,40 en cualquier subgrupo de tamaño relevante que disparan revisión humana del modelo y eventual reentrenamiento. Esta práctica formaliza la recomendación final del Informe Técnico previo y la institucionaliza como política de operación.

5.5. Propuesta para un uso ético y sostenible

La consolidación de los compromisos anteriores en una propuesta operativa unificada exige cinco elementos articulados: gobernanza, accesibilidad, formación, monitoreo y publicación abierta.

- **Gobernanza institucional:** designación de un responsable formal del sistema rol equivalente al "AI Owner" del NIST AI RMF (NIST, 2023) con autoridad para suspender el servicio si las métricas de equidad se degradan por debajo de los umbrales definidos.
- **Accesibilidad incorporada:** cumplimiento de las pautas WCAG 2.2 AA (W3C, 2023) en la interfaz, descripción textual de toda visualización generada, compatibilidad con lectores de pantalla y soporte de comandos por voz.
- **Formación de usuarios:** cualquier despliegue se acompaña de una sesión de formación obligatoria que comunica las limitaciones del sistema, los subgrupos donde el desempeño es menor, y los protocolos para identificar y reportar respuestas incorrectas.
- **Monitoreo continuo y auditoría externa anual:** a las métricas de equidad operativas se añade una auditoría externa anual independiente que valida los resultados internos y emite recomendaciones públicas.
- **Publicación abierta de hallazgos:** el equipo se compromete a publicar los hallazgos relevantes incluyendo limitaciones detectadas y mitigaciones aplicadas en formato académico abierto, contribuyendo así al cuerpo de conocimiento sobre Text-to-SQL en español y a la transparencia metodológica del campo.

6. Conclusiones y Declaración de Responsabilidad Ética

6.1. Conclusiones

La reflexión ética desarrollada en la sexta semana del Proyecto Integrador (25 de abril – 1 de mayo de 2026) confirma que el proyecto Text-to-SQL del Grupo 1 constituye un prototipo académico funcional con aporte relevante al estado del arte local, pero que presenta riesgos éticos cuantificables que exigen mitigaciones explícitas antes de cualquier despliegue productivo. Los siete riesgos identificados tres de ellos respaldados por evidencia empírica directa de las fases previas del proyecto: DR = 0,499 por longitud de pregunta, DR = 0,674 por presencia de JOIN, DR = 0,620 por dominio de base de datos se distribuyen de manera asimétrica entre los grupos de usuarios y configuran un mapa de impacto diferencial que el diseño del sistema debe atender intencionalmente.

El mapeo de stakeholders bajo el marco Value Sensitive Design reveló doce actores distintos con valores en juego no siempre convergentes. Las tres tensiones principales autonomía versus seguridad, eficiencia versus equidad, innovación versus integridad no admiten solución única; admiten decisiones explícitas que el equipo asume documentando sus razonamientos y consecuencias.

El balance de impacto social del sistema es positivo en condiciones de uso supervisado, pero negativo si se despliega sin las salvaguardas formuladas en el apartado 5. Los beneficios de democratización del acceso analítico, reducción de carga técnica y formación de capacidades locales son reales, pero sólo se materializan plenamente cuando los riesgos de amplificación de desigualdades, deskilling, concentración informacional y desplazamiento de responsabilidad están adecuadamente gestionados.

Las recomendaciones derivadas de esta reflexión alimentarán el workshop de simulación de escenarios críticos previsto para la séptima semana del cronograma (2 al 8 de mayo de 2026) y se consolidarán en el informe final de la octava semana (9 al 15 de mayo de 2026). De este modo, la presente actividad no se cierra sobre sí misma, sino que opera como bisagra entre lo ya construido y lo que aún queda por construir en el periodo restante del proyecto.

6.2. Declaración de Responsabilidad Ética

El equipo investigador, conformado por Cabrera Parrales Joel David y Sánchez Arévalo Aníbal Andrés, en el marco del Proyecto Integrador en Inteligencia Artificial de la Maestría en Inteligencia Artificial de la Universidad de Especialidades Espíritu Santo, suscrito durante el periodo de elaboración comprendido entre el 21 de marzo y el 15 de mayo de 2026, asume formal y públicamente los siguientes compromisos operativos respecto al sistema desarrollado:

- **Compromiso de transparencia:** Reportar honestamente todos los hallazgos, incluyendo el data leakage detectado, las disparidades cuantificadas y las limitaciones de generalización del modelo, sin alterar resultados para favorecer la percepción del proyecto.
- **Compromiso de supervisión humana:** Mantener el sistema como herramienta de asistencia y nunca como decisor autónomo, exhibiendo el SQL y permitiendo edición humana antes de toda ejecución.
- **Compromiso de privacidad:** Aplicar el principio de minimización de datos, restringir la operación a SELECT, registrar todas las consultas con fines auditables, y abstenerse de utilizar datos personales fuera del propósito declarado.
- **Compromiso de equidad:** Monitorear continuamente las métricas de equidad por subgrupo y suspender el servicio si los umbrales definidos se degradan.
- **Compromiso de no despliegue prematuro:** Reconocer que el prototipo actual contiene un data leakage estructural que invalida los valores absolutos de métricas reportados, y comprometerse a no desplegar el sistema en entornos productivos hasta resolver esta limitación reformulando la tarea sobre la pregunta natural únicamente.
- **Compromiso de mejora continua:** Incorporar retroalimentación de los usuarios y de la tutora del proyecto, publicar las mejoras de forma trazable, y mantener una "model card" actualizada accesible al usuario final.
- **Compromiso académico:** Respetar la integridad investigativa de la UEES, reconocer todas las fuentes utilizadas mediante citación APA 7ª edición, y no adjudicar al equipo aportes que correspondan a la literatura referenciada.

Estos compromisos no constituyen una formalidad. Son condición necesaria para que el sistema, en su evolución posterior al cierre del Proyecto Integrador previsto para el 15 de mayo de 2026, pueda transitar de prototipo académico a herramienta éticamente desplegable. El equipo se reconoce a sí mismo como responsable de mantenerlos y como interlocutor disponible ante cualquier observación que el lector del presente documento desee formular.

Referencias Bibliográficas

- Asamblea Nacional del Ecuador. (2021). Ley Orgánica de Protección de Datos Personales. Registro Oficial Suplemento 459 de 26 de mayo de 2021.
- Barocas, S., Hardt, M., & Narayanan, A. (2019). Fairness and Machine Learning: Limitations and Opportunities. fairmlbook.org.
- Birhane, A., Isaac, W., Prabhakaran, V., Díaz, M., Elish, M. C., Gabriel, I., & Mohamed, S. (2022). Power to the People? Opportunities and Challenges for Participatory AI. Proceedings of the ACM Conference on Equity and Access in Algorithms, Mechanisms, and Optimization (EAAMO '22). <https://doi.org/10.1145/3551624.3555290>
- Carr, N. (2014). The Glass Cage: Automation and Us. W. W. Norton & Company.
- Daugherty, P. R., & Wilson, H. J. (2018). Human + Machine: Reimagining Work in the Age of AI. Harvard Business Review Press.
- Dwork, C., & Roth, A. (2014). The Algorithmic Foundations of Differential Privacy. Foundations and Trends in Theoretical Computer Science, 9(3-4), 211–407. <https://doi.org/10.1561/04000000042>
- Feng, Z., Guo, D., Tang, D., Duan, N., Feng, X., Gong, M., Shou, L., Qin, B., Liu, T., Jiang, D., & Zhou, M. (2020). CodeBERT: A Pre-Trained Model for Programming and Natural Languages. Findings of EMNLP 2020. <https://doi.org/10.18653/v1/2020.findings-emnlp.139>
- Floridi, L., Cows, J., Beltrametti, M., Chatila, R., Chazerand, P., Dignum, V., Luetge, C., Madelin, R., Pagallo, U., Rossi, F., Schafer, B., Valcke, P., & Vayena, E. (2018). AI4People An Ethical Framework for a Good AI Society. Minds and Machines, 28, 689–707. <https://doi.org/10.1007/s11023-018-9482-5>
- Friedman, B., Hendry, D. G., & Borning, A. (2017). A Survey of Value Sensitive Design Methods. Foundations and Trends in Human–Computer Interaction, 11(2), 63–125. <https://doi.org/10.1561/11000000015>
- Goddard, K., Roudsari, A., & Wyatt, J. C. (2012). Automation bias: a systematic review of frequency, effect mediators, and mitigators. Journal of the American Medical Informatics Association, 19(1), 121–127. <https://doi.org/10.1136/amiajnl-2011-000089>
- High-Level Expert Group on Artificial Intelligence (HLEG-AI). (2019). Ethics Guidelines for Trustworthy AI. European Commission.
- Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems 30. <https://doi.org/10.48550/arXiv.1705.07874>
- Matthias, A. (2004). The responsibility gap: Ascribing responsibility for the actions of learning automata. Ethics and Information Technology, 6, 175–183. <https://doi.org/10.1007/s10676-004-3422-1>

- Mehrabi, N., Morstatter, F., Saxena, N., Lerman, K., & Galstyan, A. (2021). A Survey on Bias and Fairness in Machine Learning. *ACM Computing Surveys*, 54(6), 1–35. <https://doi.org/10.1145/3457607>
- Mendelow, A. (1991). Stakeholder Mapping. *Proceedings of the 2nd International Conference on Information Systems*, Cambridge, MA.
- Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model Cards for Model Reporting. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)*. <https://doi.org/10.1145/3287560.3287596>
- NIST. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). National Institute of Standards and Technology, NIST AI 100-1. <https://doi.org/10.6028/NIST.AI.100-1>
- NIST. (2024). The NIST Cybersecurity Framework (CSF) 2.0. NIST CSWP 29. <https://doi.org/10.6028/NIST.CSWP.29>
- Parlamento Europeo y Consejo de la Unión Europea. (2016). Reglamento (UE) 2016/679 General de Protección de Datos. *Diario Oficial de la Unión Europea*, L 119/1.
- Parlamento Europeo y Consejo de la Unión Europea. (2024). Reglamento (UE) 2024/1689 sobre inteligencia artificial. *Diario Oficial de la Unión Europea*, L 168/1.
- Reisman, D., Schultz, J., Crawford, K., & Whittaker, M. (2018). Algorithmic Impact Assessments: A Practical Framework for Public Agency Accountability. AI Now Institute.
- Santoni de Sio, F., & Mecacci, G. (2021). Four Responsibility Gaps with Artificial Intelligence. *Philosophy & Technology*, 34, 1057–1084. <https://doi.org/10.1007/s13347-021-00450-x>
- Scholak, T., Schucher, N., & Bahdanau, D. (2021). PICARD: Parsing Incrementally for Constrained Auto-Regressive Decoding from Language Models. *Proceedings of EMNLP 2021*. <https://doi.org/10.18653/v1/2021.emnlp-main.779>
- Selbst, A. D., Boyd, D., Friedler, S. A., Venkatasubramanian, S., & Vertesi, J. (2019). Fairness and Abstraction in Sociotechnical Systems. *Proceedings of the Conference on Fairness, Accountability, and Transparency (FAT* '19)*. <https://doi.org/10.1145/3287560.3287598>
- UNESCO. (2022). Recomendación sobre la Ética de la Inteligencia Artificial. Organización de las Naciones Unidas para la Educación, la Ciencia y la Cultura. SHS/BIO/REC-AIETHICS/2021.
- World Wide Web Consortium (W3C). (2023). Web Content Accessibility Guidelines (WCAG) 2.2. W3C Recommendation 5 October 2023.
- Yu, T., Zhang, R., Yang, K., Yasunaga, M., Wang, D., Li, Z., Ma, J., Li, I., Yao, Q., Roman, S., Zhang, Z., & Radev, D. (2018). Spider: A Large-Scale Human-Labeled Dataset for Complex and Cross-Domain Semantic Parsing and Text-to-SQL Task. *Proceedings of EMNLP 2018*. <https://doi.org/10.18653/v1/D18-1425>