



UNIVERSIDAD DE ESPECIALIDADES ESPÍRITU SANTO
MAESTRÍA EN INTELIGENCIA ARTIFICIAL

ASIGNATURA:
PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL

ACTIVIDAD:
CASO DE ESTUDIO: PROYECTOS EXITOSOS Y FALLIDOS
ANÁLISIS COMPARATIVO DE PRESENTACIONES DE PROYECTOS DE INTELIGENCIA
ARTIFICIAL

AUTORES:
CABRERA PARRALES JOEL DAVID
SÁNCHEZ ARÉVALO ANÍBAL ANDRÉS

TUTOR:
MG. ALEXANDRA J. ARCINIEGAS C.

SAMBORONDÓN – ECUADOR
ABRIL – 2026

Resumen

El presente trabajo desarrolla un análisis comparativo de presentaciones públicas de proyectos de inteligencia artificial, con el objetivo de identificar empíricamente los factores que distinguen las iniciativas exitosas de las que fracasan en el mercado o en su promesa científica. La actividad responde a los cuatro lineamientos definidos en la rúbrica: evaluación de la claridad del problema y la solución, análisis de la narrativa utilizada para comunicar el proyecto, identificación de errores comunes sobrecarga técnica, falta de enfoque y débil justificación y extracción de buenas prácticas transferibles al Proyecto Integrador del Grupo. Se analizan cinco casos representativos seleccionados por su impacto documentado y la disponibilidad de fuentes verificables: tres fracasos paradigmáticos (IBM Watson for Oncology, Zillow Offers y COMPAS) y dos éxitos paradigmáticos (AlphaFold 2 de Google DeepMind y GitHub Copilot de Microsoft). Cada caso se examina sobre seis dimensiones consistentes problema, solución, narrativa, evidencia, alcance y resultado y se contrasta posteriormente en una matriz comparativa. Los hallazgos confirman patrones documentados en la literatura sobre gestión de proyectos de IA (Davenport & Ronanki, 2018; Westenberger et al., 2022; Henke et al., 2023): los fracasos se concentran sistemáticamente en problemas de alcance excesivo, narrativa de hype desconectada de evidencia, y subestimación de las restricciones del contexto operativo, mientras los éxitos comparten alcance estrecho, rigor en la validación y publicación abierta de limitaciones. El documento cierra con un decálogo de buenas prácticas que se aplicará deliberadamente en la presentación final del Proyecto Integrador prevista para la semana 8 del cronograma (9-15 de mayo de 2026).

1. Introducción

La capacidad técnica de construir un sistema de inteligencia artificial y la capacidad de comunicarlo eficazmente son dos competencias distintas que rara vez convergen de forma automática. Un modelo con métricas excelentes puede fracasar en la fase de presentación si el equipo no logra articular con claridad el problema que resuelve, la evidencia que respalda su funcionamiento y los límites razonables de su alcance. Inversamente, una presentación brillante sobre un sistema deficiente acelera el fracaso al amplificar expectativas que el modelo no puede cumplir, configurando lo que la literatura ha denominado "hype debt" (West, 2024). El estudio comparativo de proyectos exitosos y fallidos en IA es, por lo tanto, un ejercicio de aprendizaje sobre la articulación entre lo técnico y lo comunicativo.

La actividad se enmarca dentro del cronograma del Proyecto Integrador del Grupo, comprendido entre el 21 de marzo y el 15 de mayo de 2026, y se ubica en la sexta semana del calendario académico. Las lecciones extraídas del análisis comparativo no son ornamentales: se traducen en decisiones concretas sobre cómo

estructurar la narrativa del proyecto, qué evidencia priorizar en las diapositivas, qué errores comunes evitar y qué buenas prácticas adoptar deliberadamente.

La selección de los cinco casos IBM Watson for Oncology, Zillow Offers, COMPAS, AlphaFold 2 y GitHub Copilot responde a tres criterios. Primero, representatividad: los tres fallos cubren los principales modos de falla documentados en la literatura (sobrepromesa narrativa, fragilidad técnica frente a cambios del entorno y sesgo algorítmico estructural), mientras los dos éxitos cubren tanto avance científico como producto comercial maduro. Segundo, verificabilidad: cada caso cuenta con literatura académica revisada por pares, cobertura periodística investigativa, declaraciones públicas de los actores involucrados o documentación regulatoria. Tercero, vigencia: los casos cubren un arco temporal entre 2012 y 2024, suficiente para identificar patrones recurrentes y no idiosincrasia de un momento particular.

La estructura del documento es la siguiente: el apartado 2 establece el marco metodológico para evaluar presentaciones de proyectos de IA. El apartado 3 desarrolla los tres casos fallidos. El apartado 4 desarrolla los dos casos exitosos. El apartado 5 presenta la matriz comparativa y la discusión de patrones. El apartado 6 sintetiza el decálogo de buenas prácticas y formula su aplicación específica a la presentación final del Grupo. El apartado 7 cierra con conclusiones y referencias APA 7ª edición.

2. Marco metodológico para el análisis de presentaciones

2.1. Dimensiones de análisis

Cada caso se evalúa sobre seis dimensiones que cubren los cuatro lineamientos de la rúbrica de la actividad. Las dimensiones derivan del marco de evaluación de proyectos de IA propuesto por Davenport y Ronanki (2018) en Harvard Business Review, complementado con los criterios de comunicación científica de Schimel (2012) y los principios de presentación técnica de Reynolds (2020). La Tabla 1 sintetiza la operacionalización de cada dimensión.

Dimensión	Pregunta clave	Lineamiento atendido
Problema	¿El problema está claramente acotado y justificado?	Claridad del problema
Solución	¿La solución es proporcional al problema?	Claridad de la solución
Narrativa	¿La historia es coherente, honesta y memorable?	Análisis de narrativa
Evidencia	¿Las afirmaciones se respaldan con datos verificables?	Justificación

Dimensión	Pregunta clave	Lineamiento atendido
Alcance	¿El alcance declarado es realista y limitado?	Errores comunes (foco)
Resultado	¿La promesa pública se sostuvo en el tiempo?	Resultado / aprendizaje

Tabla 1. Dimensiones de análisis de presentaciones de proyectos de IA. Marco propio elaborado a partir de Davenport y Ronanki (2018), Schimel (2012) y Reynolds (2020).

2.2. Tipología de errores comunes

La rúbrica de la actividad identifica tres errores frecuentes en presentaciones de proyectos de IA: sobrecarga técnica, falta de enfoque y débil justificación. La literatura amplía esta tipología y permite formularla con mayor precisión operativa.

- **Sobrecarga técnica:** Saturar la presentación con detalles algorítmicos, fórmulas o arquitecturas que la audiencia no necesita para evaluar el aporte del proyecto. Reynolds (2020) llama a este error "información sin propósito"; Schimel (2012) lo describe como "perder al lector en el método antes de explicar por qué importa".
- **Falta de enfoque:** Intentar abordar simultáneamente múltiples problemas, dominios o usuarios, lo que diluye la propuesta de valor y genera la percepción de que el equipo no sabe qué construye exactamente. Westenberger, Schaller y Lasi (2022) reportan en su revisión sistemática que el alcance excesivo es la primera causa de fracaso en proyectos industriales de IA.
- **Débil justificación:** Afirmar resultados sin proporcionar la evidencia que los respalde, mezclar evidencia anecdótica con métricas controladas o presentar comparaciones sesgadas con baselines débiles. Henke, Levine y McInerney (2023) documentan que esta es la causa principal de la pérdida de confianza institucional una vez el proyecto pasa a la fase de evaluación externa.
- **Hype narrativo:** Usar lenguaje hiperbólico ("revolucionaria", "cambia todo", "soluciona el problema") sin validación empírica. Es el error más visible en casos fallidos como Watson for Oncology (Strickland, 2019).
- **Inconsistencia interna:** Declarar objetivos en una diapositiva y métricas que no los miden en otra. Es uno de los signos que evaluadores expertos detectan más rápidamente.

3. Análisis de casos fallidos

3.1. Caso 1: IBM Watson for Oncology y MD Anderson Cancer Center

3.1.1. Contexto y promesa pública

En 2013, IBM y la University of Texas MD Anderson Cancer Center anunciaron el desarrollo del Oncology Expert Advisor (OEA), un sistema de soporte clínico basado en Watson cuya promesa pública era nada menos que erradicar el cáncer (Schmidt, 2017). La narrativa de lanzamiento, fuertemente respaldada por la entonces CEO de IBM Ginni Rometty, posicionó al proyecto como el "moonshot" de la compañía y atrajo más de cincuenta partnerships institucionales en pocos años (Strickland, 2019).

3.1.2. Lo que ocurrió

Cinco años y aproximadamente 62 millones de dólares después, MD Anderson canceló el contrato sin haber utilizado nunca el sistema en pacientes reales (Schmidt, 2017; Becker's Hospital Review, 2017). Una auditoría interna de la University of Texas reveló problemas de gestión, cambios sucesivos de alcance el proyecto pasó de leucemia a cáncer de pulmón sin completar ninguna y desconexión técnica entre el sistema y los registros médicos electrónicos vigentes (Becker's, 2017). Documentos internos filtrados por STAT mostraron que el sistema recomendaba en ocasiones tratamientos "inseguros e incorrectos", aunque sin daño a pacientes reales porque las recomendaciones nunca se aplicaron clínicamente (Strickland, 2019). Para 2022, IBM había vendido los activos de Watson Health a un fondo de capital privado, marcando el cierre formal de la iniciativa (Dolfing, 2024).

3.1.3. Análisis por dimensiones

Dimensión	Diagnóstico
Problema	Excesivamente amplio: "erradicar el cáncer". Sin acotación clínica operativa.
Solución	Genérica: NLP sobre literatura médica. Sin adaptación a flujos clínicos.
Narrativa	Hype extremo desde la victoria en Jeopardy! (2011). Marketing sobre evidencia.
Evidencia	Métricas internas no replicadas externamente. Casos sintéticos como entrenamiento.
Alcance	Cambió múltiples veces (leucemia → pulmón → indefinido). Falta de foco crónica.
Resultado	Cancelación contractual, USD 62M perdidos, venta de Watson Health en 2022.

Tabla 2. Análisis dimensional del caso IBM Watson for Oncology. Elaboración propia.

3.1.4. Lecciones extraídas

La principal lección es que el hype narrativo no es un complemento de marketing benigno: es una hipoteca técnica. Cuando el lenguaje promocional declara "erradicar el cáncer" pero el sistema apenas consigue procesar registros médicos heterogéneos, la brecha entre promesa y entrega erosiona la credibilidad de toda la categoría tecnológica. Strickland (2019) documenta cómo el desajuste fundamental entre las capacidades reales del sistema y las expectativas creadas configuró el fracaso desde la presentación inicial. Además, el cambio sucesivo de alcance de leucemia a cáncer de pulmón sin cerrar ninguno ilustra el error de "falta de enfoque" descrito en el apartado 2.2: intentar resolver demasiados problemas a la vez resulta en no resolver ninguno.

3.2. Caso 2: Zillow Offers y el colapso del iBuying algorítmico

3.2.1. Contexto y promesa pública

Zillow Offers fue el brazo de iBuying de Zillow Group, plataforma estadounidense líder en información inmobiliaria. La iniciativa, lanzada en 2018 y ampliada agresivamente en 2020-2021, se apoyaba en el algoritmo Zestimate para estimar el valor de viviendas y emitir ofertas automáticas de compra. La narrativa pública posicionaba a Zillow como "market maker, no market risk taker" capaz de pronosticar precios de vivienda con tres a seis meses de anticipación (Zillow Group, 2021).

3.2.2. Lo que ocurrió

El 2 de noviembre de 2021, Zillow anunció el cierre completo del programa, una baja contable superior a 500 millones de dólares en inventario sobrevalorado y el despido del 25% de la plantilla, aproximadamente 2.000 empleados (Zillow Group, 2021; Stanford GSB, 2021). En el comunicado oficial a inversionistas, el CEO Rich Barton reconoció textualmente que la volatilidad observada en el error de pronóstico "ha sido mucho más volátil de lo que jamás esperamos posible" (Zillow Group, 2021). El fundamento técnico del fracaso, según el análisis de Stanford GSB (2021), fue triple: el algoritmo no se recalibró cuando el mercado postpandemia se enfrió, asumió que las tendencias de 2020-2021 eran sostenibles y subestimó la complejidad dinámica de un activo cuyo valor depende de variables que el modelo no capturaba (estilo arquitectónico, ruido del barrio, calidad del mantenimiento del vecindario).

3.2.3. Análisis por dimensiones

Dimensión	Diagnóstico
Problema	Acotado: estimar valor de viviendas. Pero sin modelar incertidumbre temporal.
Solución	Algoritmo Zestimate sin recalibración ante drift de mercado.

Dimensión	Diagnóstico
Narrativa	Confianza excesiva en el algoritmo. "Market maker, not market risk taker".
Evidencia	Métricas de error in-sample, sin pruebas de robustez ante cambios de régimen.
Alcance	Crecimiento acelerado: 3.805 casas en Q2 2021 (>2x el trimestre anterior).
Resultado	USD 500M+ en pérdidas, cierre del programa, despido del 25% de la plantilla.

Tabla 3. Análisis dimensional del caso Zillow Offers. Elaboración propia con base en Zillow Group (2021) y Stanford GSB (2021).

3.2.4. Lecciones extraídas

Zillow Offers ilustra dos errores adicionales que toda presentación técnica debe prevenir. El primero es la confusión entre precisión y robustez: el Zestimate era razonablemente preciso en condiciones estables, pero las presentaciones públicas de Zillow no comunicaron adecuadamente la fragilidad del modelo ante cambios de régimen del mercado. El segundo es la asimetría de la narrativa de éxito: cuando el algoritmo funcionaba se atribuía a la sofisticación tecnológica; cuando dejó de funcionar, se atribuyó a "circunstancias extraordinarias del mercado". Esta asimetría es un patrón típico de presentaciones que no establecen baselines de comparación honestos. Para el Grupo, la lección directa es: cualquier diapositiva que reporte una métrica de desempeño debe acompañarse de su intervalo de confianza y de un enunciado explícito sobre las condiciones de validez.

3.3. Caso 3 COMPAS y la asimetría racial en evaluación de riesgo

3.3.1. Contexto y promesa pública

COMPAS (Correctional Offender Management Profiling for Alternative Sanctions) es un sistema de evaluación de riesgo de reincidencia criminal desarrollado por Northpointe (rebrandado a Equivant en 2017) y desplegado en cortes estadounidenses para informar decisiones sobre fianza y sentencia. La promesa pública del sistema se centraba en aportar objetividad estadística a un proceso históricamente sesgado por la subjetividad humana (Angwin et al., 2016).

3.3.2. Lo que ocurrió

En mayo de 2016, ProPublica publicó la investigación "Machine Bias", basada en el análisis de los puntajes COMPAS de más de 7.000 personas arrestadas en Broward County, Florida (Angwin et al., 2016). Los hallazgos, replicados después por múltiples investigadores académicos (Chouldechova, 2017; Hamilton, 2019), mostraron que los acusados afroamericanos eran clasificados incorrectamente como de alto riesgo

aproximadamente al doble de la tasa que los acusados blancos cuando no reincidían efectivamente mientras los acusados blancos eran clasificados incorrectamente como de bajo riesgo a una tasa proporcionalmente mayor cuando sí reincidían. Northpointe respondió con un análisis técnico (Dieterich et al., 2016) argumentando que el sistema cumplía un criterio distinto de equidad calibración igual entre grupos y que la divergencia con ProPublica reflejaba diferentes definiciones matemáticas de fairness. Chouldechova (2017) demostró formalmente que los criterios de fairness invocados por ambas partes son matemáticamente incompatibles cuando las tasas base de reincidencia difieren entre grupos, lo que abrió un campo entero de investigación sobre la imposibilidad de fairness universal en clasificación.

3.3.3. Análisis por dimensiones

Dimensión	Diagnóstico
Problema	Acotado: predecir reincidencia. Pero ignoró las consecuencias diferenciales.
Solución	Modelo propietario (caja negra). Sin posibilidad de auditoría externa.
Narrativa	Apelación a la objetividad estadística. Sin definir qué fairness se mide.
Evidencia	Métricas de calibración. Omisión de tasas de falsos positivos por grupo.
Alcance	Despliegue masivo en cortes sin marcos de auditoría algorítmica obligatoria.
Resultado	Litigios, debate académico permanente y reformas regulatorias en curso.

Tabla 4. Análisis dimensional del caso COMPAS. Elaboración propia con base en Angwin et al. (2016) y Chouldechova (2017).

3.3.4. Lecciones extraídas

COMPAS es el caso que más directamente conversa con el Proyecto Integrador del Grupo, que también es un clasificador con disparidades cuantificadas por subgrupo. La lección presentacional clave es que ninguna métrica agregada es éticamente suficiente cuando las consecuencias del error son diferenciales entre grupos. Una presentación honesta debe desagregar el desempeño por las variables sensibles relevantes y declarar abiertamente qué definición de fairness se está optimizando. Northpointe defendió su sistema invocando una definición técnicamente correcta pero parcial de fairness; ese argumento, técnicamente válido, fue insuficiente como narrativa pública porque ignoró el costo asimétrico de los errores. Como ya documentamos en nuestro Informe de Reflexión Ética (semana 6), el Grupo ha asumido el compromiso de desagregar todas las métricas por longitud de pregunta, presencia de JOIN y dominio en la presentación final.

4. Análisis de casos exitosos

4.1. Caso 4: AlphaFold 2 de Google DeepMind

4.1.1. Contexto y promesa pública

AlphaFold 2 es un modelo de aprendizaje profundo desarrollado por Google DeepMind para predecir la estructura tridimensional de proteínas a partir de la secuencia de aminoácidos. Su lanzamiento al CASP14 en diciembre de 2020 abordó lo que la biología estructural llamaba durante cinco décadas el "problema del plegamiento de proteínas" (Jumper et al., 2021). La promesa pública fue inusualmente acotada para un proyecto de IA de gran envergadura: predecir estructuras proteicas con exactitud comparable a métodos experimentales.

4.1.2. Lo que ocurrió

En CASP14 (diciembre 2020), AlphaFold 2 obtuvo una mediana de exactitud (RMSD_95) inferior a 1 Ångström, aproximadamente tres veces más precisa que el siguiente competidor y comparable a métodos experimentales (DeepMind, 2024). En julio de 2021, los autores publicaron en Nature la metodología completa (Jumper et al., 2021), abrieron el código fuente y, en colaboración con el European Bioinformatics Institute (EMBL-EBI), liberaron una base de datos pública con predicciones de más de 350.000 estructuras de 21 organismos modelo (Method of the Year, Nature Methods, 2022). Para 2022, la base de datos cubría más de 200 millones de estructuras predichas. En octubre de 2024, Demis Hassabis y John Jumper recibieron el Premio Nobel de Química por este trabajo (Nobel Prize Press Release, 2024). Para 2024, AlphaFold había sido utilizado por más de dos millones de investigadores en 190 países (Nobel Prize Popular Information, 2024).

4.1.3. Análisis por dimensiones

Dimensión	Diagnóstico
Problema	Estrechamente acotado: una tarea bien definida con benchmark de 50 años.
Solución	Específica: arquitectura Evoformer + atención. No "IA general" ni omnipotente.
Narrativa	Sobria. Se evita "revolucionar la biología"; se reporta resultado en CASP14.
Evidencia	Validación externa pública (CASP14). Paper en Nature con 60 pp. de suplementario.
Alcance	Limitado a estructura monomérica al inicio. Extensiones posteriores incrementales.
Resultado	Premio Nobel 2024. 200M+ estructuras públicas. 2M+ usuarios en 190 países.

Tabla 5. Análisis dimensional del caso AlphaFold 2. Elaboración propia con base en Jumper et al. (2021) y Nobel Prize (2024).

4.1.4. Lecciones extraídas

La narrativa de AlphaFold 2 es ejemplar precisamente por lo que no hace. No declara "revolucionar la biología": permite que CASP14 lo declare por ella. No promete aplicaciones médicas inmediatas: enumera limitaciones (estructuras monoméricas únicamente al inicio, sin cofactores ni ligandos). No oculta el código: lo abre con 60 páginas de suplementario reproducible. La combinación de problema acotado, validación externa rigurosa, publicación abierta y reporte honesto de limitaciones es el patrón que distingue las presentaciones técnicas exitosas en IA. Para el Grupo, la lección directa es que la presentación final debe seguir este modelo: declarar el problema con precisión, reportar métricas en validación independiente, abrir el código y los datos en la medida posible, y enumerar limitaciones explícitamente. La sobriedad narrativa no debilita la propuesta: la fortalece.

4.2. Caso 5: GitHub Copilot de Microsoft y OpenAI

4.2.1. Contexto y promesa pública

GitHub Copilot es un asistente de programación basado en modelos de lenguaje desarrollado por GitHub (Microsoft) en colaboración con OpenAI, lanzado en preview técnica en 2021 y comercialmente en 2022. La narrativa pública evitó deliberadamente el lenguaje de "reemplazar programadores": se presentó desde el inicio como "AI pair programmer", una herramienta de asistencia que sugiere código mientras el humano mantiene autoría y revisión (Peng et al., 2023).

4.2.2. Lo que ocurrió

Para julio de 2025, GitHub Copilot acumulaba aproximadamente 20 millones de usuarios y 1,3 millones de suscriptores pagados (Quantumrun, 2026). La adopción en empresas Fortune 100 alcanzaba el 90%. Un experimento controlado conducido por Peng et al. (2023) con 95 desarrolladores reclutados encontró que el grupo con acceso a Copilot completaba la tarea de implementar un servidor HTTP en JavaScript un 55,8% más rápido que el grupo de control. Estudios posteriores con muestras mayores (Cui et al., 2024; arXiv preprint) reportaron incrementos del 26,08% en tareas completadas en condiciones de campo, con mayores ganancias para desarrolladores menos experimentados. Estudios independientes (Brandtzæg et al., 2025) aportaron matices: la adopción no aumentó automáticamente las métricas de actividad agregadas en todos los equipos, lo que llevó a comunicación más matizada por parte de GitHub.

4.2.3. Análisis por dimensiones

Dimensión	Diagnóstico
Problema	Acotado: acelerar tareas repetitivas de codificación. Sin reemplazo humano.
Solución	Asistente integrado al flujo de trabajo (IDE). Aceptación opt-in por sugerencia.
Narrativa	"AI pair programmer". Acompañamiento, no sustitución. Honestidad operativa.
Evidencia	Experimento controlado (Peng et al., 2023). +55,8% velocidad. Replicaciones.
Alcance	Una tarea concreta: completar código. Extensiones posteriores incrementales.
Resultado	20M+ usuarios. 90% Fortune 100. Categoría de mercado consolidada.

Tabla 6. Análisis dimensional del caso GitHub Copilot. Elaboración propia con base en Peng et al. (2023) y Quantumrun (2026).

4.2.4. Lecciones extraídas

GitHub Copilot ejemplifica una narrativa madura para herramientas de IA generativa: el sistema se presenta como "augmentation" (aumento de capacidad humana) en lugar de "automation" (sustitución del humano). La metáfora del "pair programmer" es cognitivamente acertada porque mantiene al desarrollador en el rol de autor responsable. Esta narrativa no es accidental: refleja una decisión estratégica de comunicación informada por experimentos controlados con métricas verificables (Peng et al., 2023). Para el Grupo, esta lección refuerza la posición ya adoptada en la Reflexión Ética (semana 6): el sistema Text-to-SQL se presenta como herramienta de asistencia, no como decisor autónomo. La presentación final debe articular esta posición narrativamente y respaldarla con evidencia de comportamiento del sistema.

5. Análisis comparativo y patrones

5.1. Matriz comparativa consolidada

La Tabla 7 presenta la comparación de los cinco casos sobre las seis dimensiones del marco metodológico. La codificación cromática facilita la lectura: las celdas en gris claro indican fortalezas, las celdas en gris oscuro indican debilidades. La concentración de debilidades en los tres primeros casos versus la concentración de fortalezas en los dos últimos no es un artificio narrativo sino un hallazgo empírico replicable.

Dimensión	Watson	Zillow	COMPAS	AlphaFold	Copilot
Problema	✗ Difuso	✓ Acotado	✓ Acotado	✓ Acotado	✓ Acotado
Solución	✗ Genérica	● Frágil	✗ Caja negra	✓ Específica	✓ Integrada
Narrativa	✗ Hype	✗ Confianza alta	● Objetividad	✓ Sobria	✓ Augmentation
Evidencia	✗ Casos sintéticos	● In-sample	● Parcial	✓ CASP14 + paper	✓ Experimentos
Alcance	✗ Cambiante	✗ Acelerado	● Despliegue	✓ Limitado	✓ Una tarea
Resultado	✗ Cancelado	✗ Cierre + 500M	✗ Litigios	✓ Premio Nobel	✓ 20M usuarios

Tabla 7. Matriz comparativa de los cinco casos sobre las seis dimensiones del marco metodológico. Verde claro = fortaleza · Naranja = ambiguo · Rojo claro = debilidad. Elaboración propia.

5.2. Patrones identificados

5.2.1. Patrón de fracaso: alcance amplio + narrativa de hype

Los tres casos fallidos comparten dos características que se refuerzan mutuamente: alcance que crece o cambia durante el desarrollo, y narrativa pública que promete más de lo que la evidencia permite sostener. Watson buscó "erradicar el cáncer" mientras cambiaba de leucemia a pulmón; Zillow buscó volverse "market maker" mientras escalaba de cientos a miles de compras trimestrales sin recalibrar; COMPAS buscó objetividad estadística mientras desplegaba un modelo propietario sin auditoría. La narrativa amplia y el alcance creciente son síntomas de la misma enfermedad: la incapacidad institucional de decir "este sistema hace esto y no hace aquello". Davenport y Ronanki (2018) lo documentan como "moonshot fallacy": el error de tratar problemas complejos con anuncios ambiciosos en lugar de hitos verificables.

5.2.2. Patrón de éxito: alcance estrecho + narrativa sobria + evidencia abierta

Los dos casos exitosos comparten lo opuesto: problema estrechamente acotado, narrativa sobria que evita lenguaje hiperbólico, evidencia validada externamente y publicación abierta de metodología y limitaciones. AlphaFold 2 ganó CASP14 antes de cualquier comunicado de prensa significativo, publicó código y suplementario completo, y dejó que el campo declarara la magnitud del avance. GitHub Copilot se presentó como "pair programmer" desde el inicio, respaldado por experimento controlado y matizado por estudios

posteriores que reconocieron limitaciones. La fórmula es replicable y, lo que es relevante para nosotros, es exactamente la fórmula que el Grupo puede adoptar para la presentación final del 9-15 de mayo de 2026.

5.2.3. *Patrón transversal: la calidad de la presentación predice el resultado*

El tema importante del análisis comparativo es que la calidad de la presentación inicial es un predictor sustantivo del resultado final del proyecto. Los proyectos que se presentaron con narrativa hiperbólica, evidencia débil y alcance ambiguo fracasaron; los proyectos que se presentaron con narrativa sobria, evidencia rigurosa y alcance limitado tuvieron éxito. La presentación no es un envoltorio del trabajo técnico: es un componente del trabajo técnico. Reynolds (2020) lo formula como principio: "una presentación honesta es una continuación natural de un proceso honesto; una presentación deshonesto señala un proceso comprometido".

6. Decálogo de buenas prácticas y aplicación al Proyecto Integrador

6.1. Decálogo extraído del análisis comparativo

Los siguientes diez principios sintetizan las buenas prácticas extraídas del análisis comparativo. Cada principio se formula en imperativo operativo y se acompaña del caso o casos que lo respaldan empíricamente.

- **1. Acota el problema antes de presentar la solución.** Una presentación que dedique tres minutos a explicar exactamente qué problema resuelve es más fuerte que una que dedique veinte segundos a un objetivo amplio (AlphaFold, Copilot vs Watson).
- **2. Reporta evidencia, no anuncios.** Cualquier afirmación de desempeño debe acompañarse de la métrica, el conjunto de validación y el intervalo de confianza (Peng et al., 2023; Jumper et al., 2021).
- **3. Desagrega el desempeño por subgrupo.** Una métrica agregada oculta disparidades que cambian la valoración ética del sistema (lección crítica de COMPAS).
- **4. Declara limitaciones explícitamente.** No es debilidad presentacional: es señal de madurez metodológica. AlphaFold publicó 60 páginas de limitaciones junto con el modelo.
- **5. Evita lenguaje hiperbólico.** "Revoluciona", "soluciona", "cambia todo" son red flags. El lenguaje sobrio comunica más confianza que el lenguaje hiperbólico (anti-patrón Watson).
- **6. Mantén consistencia entre objetivos y métricas.** Si el objetivo es minimizar daño en grupos vulnerables, la métrica primaria debe ser desempeño en el peor subgrupo, no F1 macro promedio.

- **7. Posiciona el sistema como augmentation, no automation.** Cuando hay autoridad humana en el flujo, comunícalo explícitamente. La metáfora del "pair programmer" funciona (lección de Copilot).
- **8. Abre código, datos y metodología en la medida posible.** La reproducibilidad pública es un multiplicador de credibilidad y un escudo contra acusaciones de cherry-picking (lección de AlphaFold).
- **9. Reconoce y dimensiona los riesgos detectados.** En nuestro caso particular, comunicar abiertamente el data leakage detectado y dimensionar su impacto es la única opción coherente con la integridad investigativa UEES.
- **10. Termina con próximos pasos verificables, no aspiraciones.** Los próximos pasos deben ser concretos, fechados y observables. "Mejorar el modelo" es aspiración; "reentrenar con embeddings CodeBERT y reportar fairness desagregada antes del 15 de mayo" es próximo paso verificable.

6.2. Aplicación al Proyecto Integrador del Grupo

La aplicación del decálogo al Proyecto Integrador del Grupo se traduce en decisiones concretas para la presentación final ante el Comité Académico UEES, prevista para la semana 8 del cronograma (9-15 de mayo de 2026). La Tabla 8 articula cada principio del decálogo con su materialización específica en la presentación.

Principio	Aplicación específica al Proyecto Integrador
1. Acotar problema	Slide inicial: "Clasificación de dificultad SQL desde pregunta natural". No "revolucionar BI conversacional".
2. Evidencia	Cada métrica acompañada de su conjunto de validación: F1 macro = 0,5847 (val) y no agregado de train+val.
3. Desagregación	Tabla obligatoria de desempeño por longitud, JOIN y dominio. DR = 0,499; 0,674; 0,620.
4. Limitaciones	Slide explícito de limitaciones: data leakage detectado, sobreajuste 0,388, robustez RSI 0,479.
5. Sin hype	Eliminar términos como "revolucionario", "óptimo", "definitivo". Sustituir por "exploratorio", "bajo restricciones".
6. Consistencia obj-métrica	Si el objetivo declara equidad, la métrica primaria debe ser DR mínimo, no accuracy promedio.
7. Augmentation	Slide con SQL siempre visible y editable por el usuario. Sistema como asistente, no decisor.

Principio	Aplicación específica al Proyecto Integrador
8. Apertura	Repositorio público con código, datasets de prueba y model card al cierre del proyecto.
9. Riesgos dimensionados	Slide dedicado al data leakage con cuantificación de impacto y plan de remediación.
10. Próximos pasos verificables	Cronograma concreto post-cierre: reformulación pregunta-only, reentrenamiento CodeBERT, auditoría externa.

Tabla 8. Aplicación del decálogo de buenas prácticas a la presentación final del Proyecto Integrador del Grupo.
Elaboración propia.

7. Conclusiones

El análisis comparativo de cinco casos paradigmáticos tres fallidos y dos exitosos confirma que la calidad de la presentación pública de un proyecto de IA es un predictor sustantivo de su resultado final. Los fracasos de IBM Watson for Oncology, Zillow Offers y COMPAS comparten patrones identificables y prevenibles que son un alcance amplio o cambiante, narrativa hiperbólica o autocomplaciente, evidencia parcial o no validada externamente y subestimación de las restricciones del contexto operativo. Los éxitos de AlphaFold 2 y GitHub Copilot comparten la fórmula opuesta del problema estrechamente acotado, narrativa sobria que evita el hype, evidencia validada externamente y publicación abierta tanto de capacidades como de limitaciones.

Los tres errores comunes identificados en la rúbrica de la actividad sobrecarga técnica, falta de enfoque y débil justificación se confirmaron empíricamente en los casos analizados, particularmente en Watson y COMPAS. Las buenas prácticas sintetizadas en el decálogo del apartado 6.1 son operacional y se traducen en decisiones concretas para la presentación final del Proyecto Integrador del Grupo, según se detalla en la Tabla 8.

La principal conclusión metodológica del trabajo es que el rigor de la presentación es continuación natural del rigor del proceso. Una presentación que oculta limitaciones señala un proceso que las desconoce o las minimiza; una presentación que las declara con precisión señala un proceso que las ha caracterizado. Para el Grupo, este principio se materializa en una decisión deliberada: la presentación ante el Comité Académico UEES en la semana 8 del cronograma reportará abiertamente el data leakage detectado, las disparidades de fairness cuantificadas, la fragilidad de robustez observada y los compromisos asumidos en la Reflexión Ética de la semana 6. Esta posición no debilita la presentación: la fortalece, en línea con el patrón replicable observado en los casos exitosos analizados.

Referencias Bibliográficas

- Angwin, J., Larson, J., Mattu, S., & Kirchner, L. (2016, mayo 23). Machine Bias: There's software used across the country to predict future criminals. And it's biased against blacks. ProPublica. <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
- Becker's Hospital Review. (2017, marzo 8). 4 reasons MD Anderson put IBM Watson on hold. <https://www.beckershospitalreview.com/healthcare-information-technology/5-things-to-know-about-the-md-anderson-ibm-watson-breakup/>
- Brandtzæg, E. G. (2025). GitHub Copilot's impact on software developer productivity: A longitudinal mixed-methods case study. arXiv preprint arXiv:2509.20353.
- Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2), 153-163. <https://doi.org/10.1089/big.2016.0047>
- Cui, Z. K., Demirer, M., Jaffe, S., Musolff, L., Peng, S., & Salesi, T. (2024). The effects of generative AI on high-skilled work: Evidence from three field experiments with software developers. SSRN Working Paper 4945566.
- Davenport, T. H., & Ronanki, R. (2018). Artificial intelligence for the real world. *Harvard Business Review*, 96(1), 108-116.
- DeepMind. (2024). AlphaFold timeline. Google DeepMind. <https://deepmind.google/science/alphafold/>
- Dieterich, W., Mendoza, C., & Brennan, T. (2016). COMPAS Risk Scales: Demonstrating Accuracy Equity and Predictive Parity. Northpointe Inc.
- Dolfing, H. (2024, diciembre). Case Study 20: The \$4 Billion AI Failure of IBM Watson for Oncology. <https://www.henricodolfing.com/2024/12/case-study-ibm-watson-for-oncology-failure.html>
- Hamilton, M. (2019). The biased algorithm: Evidence of disparate impact on Hispanics. *American Criminal Law Review*, 56(4), 1553-1577.
- Henke, N., Levine, J., & McInerney, P. (2023). The state of AI in 2023: Generative AI's breakout year. McKinsey Global Institute Report.
- Jumper, J., Evans, R., Pritzel, A., Green, T., Figurnov, M., Ronneberger, O., Tunyasuvunakool, K., Bates, R., Židek, A., Potapenko, A., Bridgland, A., Meyer, C., Kohl, S. A. A., Ballard, A. J., Cowie, A., Romera-Paredes, B., Nikolov, S., Jain, R., Adler, J., ... Hassabis, D. (2021). Highly accurate protein structure prediction with AlphaFold. *Nature*, 596(7873), 583-589. <https://doi.org/10.1038/s41586-021-03819-2>
- Method of the Year 2021. (2022). Protein structure prediction. *Nature Methods*, 19(1), 1-1. <https://doi.org/10.1038/s41592-021-01380-4>
- Nobel Prize Press Release. (2024, octubre 9). The Nobel Prize in Chemistry 2024. The Royal Swedish Academy of Sciences. <https://www.nobelprize.org/prizes/chemistry/2024/press-release/>
- Peng, S., Kalliamvakou, E., Cihon, P., & Demirer, M. (2023). The impact of AI on developer productivity: Evidence from GitHub Copilot. arXiv preprint arXiv:2302.06590.
- Quantumrun. (2026, enero 9). GitHub Copilot Statistics 2026. <https://www.quantumrun.com/consulting/github-copilot-statistics/>
- Reynolds, G. (2020). *Presentation Zen: Simple ideas on presentation design and delivery* (3rd ed.). New Riders.
- Schimel, J. (2012). *Writing science: How to write papers that get cited and proposals that get funded*. Oxford University Press.
- Schmidt, C. (2017). M. D. Anderson breaks with IBM Watson, raising questions about artificial intelligence in oncology. *Journal of the National Cancer Institute*, 109(5), dxj113. <https://doi.org/10.1093/jnci/djx113>
- Stanford Graduate School of Business. (2021, diciembre 9). Flip flop: Why Zillow's algorithmic home buying venture imploded. <https://www.gsb.stanford.edu/insights/flip-flop-why-zillows-algorithmic-home-buying-venture-imploded>
- Strickland, E. (2019). How IBM Watson overpromised and underdelivered on AI health care. *IEEE Spectrum*, 56(4), 24-31.
- West, S. M. (2024). The hype debt of artificial intelligence. AI Now Institute Working Paper.
- Westenberger, J., Schaller, T., & Lasi, H. (2022). Failure of AI projects: Understanding the critical factors. *Procedia Computer Science*, 196, 69-76. <https://doi.org/10.1016/j.procs.2021.11.074>
- Zillow Group. (2021, noviembre 2). Form 8-K, Q3 2021 shareholder letter. U.S. Securities and Exchange Commission. <https://www.sec.gov/Archives/edgar/data/0001617640/000161764021000085/exhibit993.htm>